



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES

Análisis temporal y regional de *drivers* de satisfacción del cliente

Tesis de Licenciatura en Ciencias de Datos

Cristian Antonio

Director: Dr. Sebastián Pinto

Codirectores: Dra. Caterina Mosto y Lic. Santiago Kahane

Buenos Aires, 2026

ANÁLISIS TEMPORAL Y REGIONAL DE *DRIVERS* DE SATISFACCIÓN DEL CLIENTE

Esta tesis realiza un análisis temporal y regional de los determinantes (drivers) de la satisfacción del cliente en una cadena de supermercados entre junio de 2021 y marzo de 2026. A partir de las respuestas a cuestionarios de satisfacción, se parte de un modelo lineal simple y se incorporan progresivamente distintas estrategias para abordar los principales desafíos del problema. En primer lugar, ante la fragmentación estructural provocada por distintas versiones del cuestionario y la presencia de respuestas faltantes o no evaluativas, se implementó un proceso de armonización de variables junto con algoritmos de Imputación Múltiple mediante Ecuaciones Encadenadas (MICE). Luego, para tratar el fuerte desbalance de la variable de satisfacción global, se adoptó una estrategia basada en Mínimos Cuadrados Ponderados (WLS), combinada con Selección Secuencial de Características (SFS). Esto permitió obtener un modelo reducido de $K = 20$ variables interpretables sin perder capacidad de generalización. Además, la tesis analiza posibles asimetrías en el efecto de los drivers mediante un modelo compatible con la lógica de aversión a la pérdida. Los resultados muestran que, para algunos atributos, una mala evaluación puede penalizar la satisfacción global más de lo que una buena evaluación la aumenta. Finalmente, el análisis por formato de tienda (Grande, Mediano y Chico) muestra que la relevancia de los drivers no es completamente homogénea, y que la segmentación permite identificar diferencias importantes en la forma en que se construye la satisfacción del cliente.

Palabras clave: Drivers de satisfacción, Grocery Retail, Loss Aversion, Sequential Feature Selection.

AGRADECIMIENTOS

Fue un camino difícil. Con esta tesis no solo cierro una etapa académica, sino también una de superación personal. Llegué a un lugar al que creí que nunca llegaría. Nada de esto habría sido posible sin mis viejos, que siempre estuvieron y me sostuvieron en mis momentos más difíciles. A ellos les debo todo lo bueno que tengo. Me enseñaron a no bajar nunca los brazos. Mamá, Papá, Sonia, Carlos: gracias por ser mis viejos y por ayudarme a luchar por cumplir mis sueños.

A mi hermana, Carla, por haberme acompañado desde el principio de mi vida y haber estado siempre presente. Por ayudarme a crecer y superarme. Y además por haberme dado, junto con Fabi, la alegría de ser tío de la personita más especial del mundo, Elena.

A mi primo Pablo, que, más que un primo, es un hermano, me acompañó en algunos de mis momentos más difíciles. Además de ser el principal responsable de que haya elegido Exactas para estudiar.

A toda mi familia, a mis primos y a mis tíos. Todos contribuyeron de alguna forma a que yo esté hoy aquí, brindándome cariño y apoyo siempre que lo necesité. A mis abuelos y a mi tía Tita, que ya no están presentes físicamente, pero sí en mis recuerdos. Muchos de sus consejos y frases todavía me acompañan y me ayudan a seguir adelante.

A mis amigos de la vida, Tomás, Luciano e Isidro. Toda una vida juntos, muchachos. Gracias por haber sido parte de este recorrido y haberme apoyado siempre. Y también a Mati, a quien conocí hace siete años, pero lo siento como a un amigo de toda la vida.

A mis compañeros de Matemáticas, que hicieron que mi primera etapa en la facultad fuera mucho más llevadera y estuviera llena de buenos momentos. Sin ellos no habría podido lidiar con la frustración de esos primeros años tan difíciles.

A los pibes de Datos, entre ellos Manu, Nacho, Echi, Tincho, Eze y Mateo. Por haberme ayudado en distintas etapas de la carrera a alcanzar este objetivo. Compartir las cursadas con ustedes fue recontra divertido.

A todo el cuerpo docente de la Facultad de Exactas de la UBA, por haberme brindado una formación de la que me siento orgulloso. A mis directores, Sebastián, Caterina y Santiago, por haberme guiado durante todo el proceso. La realización de esta tesis no habría sido posible sin su ayuda. Mil gracias de corazón.

Los quiero a todos.

Cristian

Índice general

Introducción	3
1. Datos y limpieza del dataset	7
1.1 Encuestas	7
1.1.1 Limpieza y unificación del set de datos	9
2. Caracterización de los features (OMITIDO POR CONFIDENCIALIDAD)	
3. Modelado de la satisfacción	11
3.1 Un modelo simple de satisfacción	11
3.2 Desbalance en la satisfacción global y modelos ponderados	13
3.3 Validación cruzada temporal	14
3.4 Reducción de drivers: PCA y feature selection	15
3.4.1 Cómo leer los coeficientes	17
3.5 Un modelo de satisfacción como variable ordinal	17
3.5.1 Medida de loss aversion para la asimetría entre evaluaciones bajas y altas	18
3.5.2 Chequeo de robustez con SFS	19
4. Un modelo de satisfacción dividido por formato de tienda (OMITIDO POR CONFIDENCIALIDAD)	
5. Conclusiones	21
A. Construcción de la base unificada	23
A.1 Tipos de cuestionario y períodos de aplicación	23
A.2 Colapso de preguntas equivalentes	23
A.2.1 Formalización	24
A.3 Construcción de una estructura común entre tipos de cuestionario	25
A.3.1 Formalización	27
B. Métricas descriptivas de la caracterización de features (OMITIDO POR CONFIDENCIALIDAD)	
C. Decisiones metodológicas para el modelado	28
C.1 Reorganización de bloques de drivers	28
C.2 Tratamiento de valores faltantes y código 5	29
C.2.1 Caracterización de celdas problemáticas	30

C.3	Estrategia de imputación de celdas problemáticas	33
C.3.1	MICE (Imputación Múltiple mediante Ecuaciones Encadenadas) . .	33
C.3.2	Criterio de selección entre estrategias de imputación	35
C.3.3	Búsqueda de hiperparámetros óptimos	36
C.3.4	Blanks estructurales y centrado de variables	38
C.4	Diagnóstico de heterocedasticidad y errores estándar robustos HC3	40
C.5	Desbalance de la variable de respuesta y modelos ponderados	41
C.6	Evaluación de robustez temporal entre modelos	42
C.7	Comparación de criterios de Feature selection y ajuste de SFS	45
C.7.1	Cálculo del aporte aproximado por bloque en el modelo PCA	45
C.7.2	Comparación de criterios de selección de features	46
C.7.3	Ajuste del criterio SFS auto-k	47
C.8	Robustez del modelo de loss aversion	48
D.	Resultados complementarios de los modelos por formato de tienda (OMITIDO POR CONFIDENCIALIDAD)	
E.	Librerías utilizadas en la implementación computacional	51

INTRODUCCIÓN

La comprensión y mejora de la experiencia del consumidor en la industria del retail de supermercados (*grocery retail*) es un problema relevante para entender cómo se construye la satisfacción del cliente. En las últimas décadas, la competencia en este sector se ha intensificado, consolidando a las grandes cadenas minoristas como actores que representan una parte importante del mercado general [1]. A diferencia de otros sectores económicos donde las transacciones son esporádicas o están mediadas por contratos a largo plazo, los supermercados se caracterizan por una alta frecuencia de compra, una exposición directa a múltiples puntos de contacto físicos, y barreras de salida o costos de cambio (*switching costs*) prácticamente nulos para el cliente. En este contexto competitivo, el diseño de experiencias de compra satisfactorias se vuelve un aspecto central para fortalecer la retención de los clientes y sustentar la rentabilidad a largo plazo [2]. Esto responde a que, en la industria de la distribución alimentaria, la relación con el consumidor depende de manera crítica de la experiencia vivida dentro del establecimiento. Durante su compra, el cliente interactúa con muchos elementos del servicio al mismo tiempo que afectan de forma agregada el desempeño general percibido. Por consiguiente, la satisfacción del consumidor no es solo un indicador descriptivo, sino una variable útil para entender y gestionar la experiencia.

Un cambio importante en el retail de supermercados durante las últimas décadas fue la diversificación de los formatos de tienda [3, 4, 5]. Por un lado, los hipermercados se caracterizan por ofrecer la conveniencia de centralizar las compras en un solo lugar [3, 6]. Por otro lado, los supermercados tradicionales, si bien suelen manejar un surtido de productos más acotado, compiten mediante la provisión de un servicio más personalizado y una experiencia adaptada a las necesidades locales [7]. En cambio, las tiendas de conveniencia se definen por un surtido estrecho y compras rápidas. Esta clasificación permite pensar que los consumidores asisten a cada formato de acuerdo con sus necesidades [8]. En consecuencia, los atributos vinculados a los productos, como variedad y precios, cobran mayor relevancia en compras mayores, mientras que los atributos de servicio y conveniencia ganan peso en las compras más pequeñas. Asimismo, la propia frecuencia de compra [9] puede hacer que el cliente preste más atención a ciertos atributos que a otros: un cliente que asiste frecuentemente a una tienda de conveniencia priorizará la accesibilidad y la velocidad de la caja, mientras que en compras regulares de supermercado puede balancear la proximidad de la tienda, los precios bajos y la disponibilidad continua de stock.

Para abordar cuantitativamente estas dimensiones de la experiencia de compra en tiendas, la literatura sobre la calidad del servicio en el retail ofrece distintos marcos de referencia. Entre ellos destaca la Escala de calidad del servicio en el retail (RSQS, por sus siglas en inglés) [10], la cual descompone la evaluación del consumidor en bloques como los aspectos físicos de la infraestructura, la confiabilidad en el cumplimiento de las promesas comerciales, las interacciones con el personal, la resolución de problemas en el punto de venta y las políticas comerciales. Esta estructuración conceptual permite clasificar la matriz de preguntas de un cuestionario en bloques de drivers para el modelado matemático. En esta línea se ubica el trabajo de referencia principal de esta tesis, elaborado por Goić, Levenier y Montoya (2021) [11], quienes proponen un análisis longitudinal que muestra que los drivers del comportamiento y la satisfacción no impactan de manera uniforme en

toda una cadena de retail, sino que su relevancia relativa puede estar condicionada por el formato de tienda elegido por el consumidor para realizar su compra.

Un aspecto importante en esta área de investigación consiste en cuestionar el supuesto tradicional de simetría en el impacto de los atributos del servicio sobre la satisfacción global. La investigación pionera en marketing y comportamiento del consumidor, consolidada por Anderson y Mittal [12], muestra que la relación entre el desempeño de un atributo específico y la satisfacción general puede ser asimétrica, cuestionando los supuestos tradicionales de linealidad simétrica. Esta premisa está asociada con los fundamentos de la economía del comportamiento y la psicología de la Teoría de los prospectos (*Prospect Theory*) formulada por Kahneman y Tversky [13], la cual postula que los individuos pueden exhibir una marcada aversión a la pérdida (*loss aversion*), procesando los estímulos negativos con mayor intensidad que los estímulos positivos de igual magnitud.

A pesar de esta evidencia empírica, parte de la literatura sobre satisfacción de clientes asume que la relación funcional entre las respuestas individuales de los clientes frente al servicio y su satisfacción global puede caracterizarse mediante una función lineal. No obstante, diversas investigaciones sugieren que una función de respuesta no lineal que incorpore explícitamente el concepto de aversión a la pérdida permite modelar el impacto de la calidad del servicio percibida incorporando una lectura más flexible [14, 15]. Bajo este enfoque, el efecto del desempeño operativo se evalúa de manera asimétrica respecto a un punto de referencia determinado por las expectativas previas del propio cliente; la respuesta puede ser más pronunciada en la región de pérdidas, cuando el servicio rinde por debajo de lo esperado, que en la región de ganancias, cuando supera el umbral de expectativa. Llevado al campo del retail de supermercados, esto permite pensar que ciertos atributos pueden funcionar como mínimos esperados por el cliente. Es decir, su buen desempeño no necesariamente genera una mejora proporcional en la satisfacción, pero una mala evaluación puede producir una penalización mayor sobre la experiencia global.

El objetivo de esta tesis consiste en realizar un análisis temporal y regional de los drivers de satisfacción del cliente en una cadena de supermercados cuya identidad se reserva por motivos de confidencialidad, a lo largo del período comprendido entre junio de 2021 y marzo de 2026, evaluando la estabilidad de sus coeficientes e identificando la presencia de efectos asimétricos compatibles con la lógica de aversión a la pérdida. Para alcanzar este propósito, se plantean objetivos específicos orientados, en primer lugar, al desarrollo de un proceso de armonización y consolidación que permita el análisis de las encuestas de satisfacción. En segundo lugar, se busca estimar y contrastar el desempeño de modelos lineales interpretables frente a modelos de variables indicadoras discretas que capturen por separado el costo de una evaluación negativa respecto al beneficio de una evaluación alta. Finalmente, se evalúa si la segmentación del modelado en función del formato de la sucursal aporta información adicional para interpretar y predecir la satisfacción.

Por acuerdos de confidencialidad con la organización que proveyó los datos, esta versión del documento omite la identidad de la empresa, así como los capítulos de resultados. El Capítulo 1 expone los aspectos metodológicos de la recolección de las encuestas y el proceso de unificación y preprocesamiento de los datos crudos. El Capítulo 2 se omite en esta versión. El Capítulo 3 describe la metodología de modelado: el modelo lineal simple ponderado, los algoritmos de reducción dimensional mediante selección secuencial de características (SFS) y el modelo de variables categóricas indicadoras diseñado para contrastar empíricamente la asimetría compatible con *loss aversion*. El Capítulo 4 se omite en esta versión. Por último, el capítulo de Conclusiones sintetiza los principales aspectos

del estudio. Los detalles metodológicos se encuentran en el Apéndice, y las principales librerías utilizadas en la implementación computacional se presentan en el Apéndice [E](#).

1. DATOS Y LIMPIEZA DEL DATASET

En este primer capítulo se describen las encuestas de las cuales provienen los datos con los que se trabaja en esta tesis. A continuación, se expone el proceso de limpieza y unificación de los archivos originales para obtener el dataset final.

1.1. Encuestas

Los datos provienen de una cadena de supermercados cuya identidad se reserva por motivos de confidencialidad.

Para el desarrollo de esta tesis, se cuenta con un conjunto de archivos provistos por la empresa. Estos registros contienen las respuestas obtenidas a través de encuestas de satisfacción dirigidas a sus clientes, realizadas con frecuencia mensual o bimestral durante el período comprendido entre junio de 2021 y marzo de 2026. Se le llamará a lo largo de esta tesis ‘ola temporal’ a cada una de las ventanas de tiempo (de uno o dos meses) en las que la empresa agrupó la recolección de las respuestas a la encuesta de satisfacción. Las mismas se realizaron virtualmente con modalidad no transaccional (posterior y no inmediata) con el objetivo de evaluar el servicio prestado en las distintas tiendas. Además, los participantes contaban con un sistema de incentivos asociado a un programa de puntos, pudiendo responder solamente una vez por ola.

El cuestionario comprende cuatro versiones a lo largo del tiempo, producto de modificaciones menores realizadas con el fin de mejorarlo. En la Figura 1.1 se observa cómo se distribuyen las 34.595 respuestas a lo largo del tiempo. Cada barra representa una ola temporal, siendo 40 en total, cuyo color está asociado al tipo de cuestionario vigente en cada período.




Fig. 1.1: Cantidad de encuestas realizadas por ola temporal y por tipo de cuestionario.

Si bien cada tipo de cuestionario presenta particularidades propias, se mantiene durante todo el período un núcleo general. Este núcleo incluye preguntas asociadas al supermer-

cado principal, la sucursal o canal de compra, la satisfacción global y distintos aspectos de la experiencia en sucursal, tales como infraestructura, variedad y disponibilidad, calidad, precios y atención, además de aspectos demográficos como género y edad. Fuera de este núcleo, se incluyen preguntas relacionadas con e-commerce, la competencia, el Net Promoter Score (NPS, por sus siglas en inglés, que es una medida de recomendación de la cadena u otro supermercado), publicidad/comunicación u otras secciones específicas según la versión. Se analiza en detalle qué representa un tipo de cuestionario en el Apéndice A.1.

Asimismo, resulta importante remarcar que, dentro de un mismo cuestionario, podían existir distintas rutas de respuesta según las características y los servicios ofrecidos por la sucursal visitada. La Tabla 1.1 resume la estructura general de los cuestionarios según tipo de respuesta. A partir de esta revisión, se identificaron 10 grandes bloques, observando que el cuestionario organiza las preguntas en torno a dimensiones temáticas.

Tab. 1.1: Tipo de respuesta y contenido de los bloques del cuestionario

Bloque	Tipo de respuesta	Descripción
General	Categórica nominal, ordinal y numérica	Incluye variables generales de clasificación, como ranking, sucursal, última visita y satisfacción global.
Demografía	Categórica nominal y ordinal	Incluye características del encuestado, principalmente edad y género.
Infraestructura	Ordinal 1–4 y códigos no evaluativos	Evalúa características físicas del local, como limpieza, baños, carritos, canastos u otros aspectos de infraestructura.
Surtido/ disponibilidad	Ordinal 1–4, códigos no evaluativos y, en algunos casos, texto libre asociado	Evalúa la variedad y disponibilidad de productos.
Calidad	Ordinal 1–4, códigos no evaluativos y, en algunos casos, texto libre asociado	Evalúa principalmente la calidad/frescura de productos y secciones específicas.
Relación calidad-precio (RCP)	Ordinal 1–4, códigos no evaluativos y, en algunos casos, texto libre asociado	Evalúa la percepción del cliente sobre la relación entre precio y calidad.
Precios	Ordinal 1–4, códigos no evaluativos y, en algunos casos, texto libre asociado	Evalúa precios por categoría, precios generales y atractivo de ofertas.
Atención/ servicio	Ordinal 1–4, códigos no evaluativos y, en algunos casos, texto libre asociado	Evalúa aspectos vinculados con atención del personal, disponibilidad del personal y tiempos de espera.
Comparación con competidor	Comparativa ordinal, NPS y texto libre asociado	Incluye comparaciones con la cadena y otros supermercados, además de preguntas de recomendación.
Publicidad y campanas	Categórica, binaria o selección múltiple, ordinal y texto libre asociado	Incluye preguntas vinculadas con campañas, publicidad y recordación de acciones comerciales.

Nota: En las escalas ordinales 1–4, los valores menores indican una evaluación más favorable. En muchos casos, el valor 5 corresponde a respuestas no evaluativas, como “No uso”, “No sabe” o equivalentes. Según la pregunta, también pueden aparecer códigos especiales, como 4 o 99, para categorías como “No sabe”, “No contesta” o equivalentes. Algunos bloques incluyen además campos de texto libre asociados a respuestas evaluativas.

Como se observa en la Tabla 1.1, en todos los bloques predominan las respuestas numéricas, con la posibilidad de ser acompañadas por texto libre en algunos casos.

1.1.1. Limpieza y unificación del set de datos

La variación estructural de los tipos de encuesta motivó la necesidad de construir una base de datos unificada. Esta etapa resultó indispensable debido a los cambios estructurales que sufrieron los cuestionarios a lo largo del tiempo, siendo necesaria la estandarización de las variables para poder consolidar una base de datos robusta, coherente y apta para el análisis posterior.

En primer lugar, se analizó la cobertura del relevamiento por sucursal a lo largo del tiempo. Se consideraron únicamente aquellas tiendas físicas con cobertura completa a lo largo del tiempo. Bajo este criterio, quedaron 13 sucursales. Con esta restricción, la mues-

tra se redujo a 26.480 observaciones. Además, dado que 2 archivos (correspondientes a 2 olas temporales) presentaban faltantes en varios bloques relevantes, se decidió excluirlos del dataset final utilizado para el análisis, por lo que la muestra se redujo a 25.117 observaciones.

Dado que los distintos tipos de cuestionario presentan diferencias estructurales, fue necesario realizar un proceso de unificación. El mismo consistió en identificar preguntas equivalentes dentro de cada cuestionario (asociadas a distintas rutas), colapsar aquellas que representaban un mismo aspecto evaluado dentro de una misma ola y luego llevar las variables resultantes a una estructura común. La descripción de cómo se llevó a cabo este procedimiento se encuentra detallada en el Apéndice A.2.

Se decidió excluir los bloques ‘Comparación con competidor’ y ‘Publicidad/Campañas’ del proceso de unificación. El bloque ‘Comparación con competidor’ se excluyó porque estos features no explican de forma directa aspectos específicos de la experiencia del cliente en sucursal, lo que dificulta su interpretación dentro del modelo. Por su parte, el bloque ‘Publicidad/Campañas’ presentó una variación importante entre preguntas, tanto entre tipos de encuesta como entre olas dentro de un mismo tipo. Además, estas preguntas tienen tipos de respuesta más difíciles de interpretar, por lo que requerirían un análisis más exhaustivo.

Para cada una de las variables retenidas después de la unificación se verificó su presencia en cada versión del cuestionario, junto con la clasificación en bloques de cada pregunta. Estos módulos apuntan a dividir el cuestionario en distintas secciones, que podrán o no estar disponibles en cada una de las tiendas, de acuerdo con los servicios prestados.

Se observó que la mayoría de las variables mantienen su presencia en los cuestionarios a lo largo del período analizado. Como se mencionó previamente, algunas de ellas presentan disponibilidad parcial debido a las variaciones que se realizaron a lo largo del tiempo.

Dado que la variable target modelada en esta tesis es la satisfacción global, resulta necesario aclarar cómo se trabajó con ella en los primeros análisis descriptivos. En la encuesta, la satisfacción global se registra mediante categorías ordinales: ‘Totalmente satisfecho’, ‘Satisfecho’, ‘Poco satisfecho’ e ‘Insatisfecho’. Como estas categorías tienen un orden claro, en esta primera etapa se las llevó a una escala numérica inicial, donde 1 corresponde a ‘Totalmente satisfecho’, 2 a ‘Satisfecho’, 3 a ‘Poco satisfecho’ y 4 a ‘Insatisfecho’.

3. MODELADO DE LA SATISFACCIÓN

En este capítulo se estudia cómo se relacionan las evaluaciones de distintos aspectos de la experiencia en sucursal con la satisfacción global reportada por los encuestados. Para esto, se partió de un modelo lineal simple y luego se incorporaron distintas modificaciones a medida que aparecieron problemas propios de la muestra. En particular, se consideró el tratamiento de celdas problemáticas, el desbalance de la variable de respuesta y la cantidad de drivers disponibles.

Luego de recorrer distintas alternativas, se eligió un modelo principal para interpretar los drivers asociados a la satisfacción global. Se buscó que el modelo conservara una lectura clara de los coeficientes, pero sin depender de un ajuste demasiado inestable.

Por motivos de confidencialidad, en esta versión se presenta únicamente la metodología de modelado: se omiten los coeficientes estimados, los drivers identificados y su interpretación.

3.1. Un modelo simple de satisfacción

En esta sección se busca estimar un primer modelo lineal simple de satisfacción global. El objetivo es estudiar en qué medida los distintos features asociados a la experiencia de compra se relacionan con la satisfacción global reportada por los encuestados.

Antes de modelar, se realizó una reorganización de los bloques de drivers utilizados en el análisis. Esta reorganización no modificó las variables originales ni sus valores, sino la forma en que fueron agrupadas para la etapa de modelado, a fin de que los bloques fueran más representativos de los drivers que contienen. Por ejemplo, el bloque original ‘Atención / servicio’ mezclaba variables vinculadas al trato del personal con variables asociadas a tiempos de espera. Por eso, se separó en dos bloques: ‘Personal y atención’ y ‘Esperas y conveniencia operativa’. Además, algunas variables asociadas a ofertas, como disponibilidad de productos en oferta y atractivo de las ofertas, se agruparon en un bloque propio llamado ‘Ofertas y promociones’. El detalle completo de los cambios realizados se presenta en el Apéndice C.1.

Asimismo, para poder modelar, fue necesario desarrollar una estrategia de imputación para las celdas problemáticas de la base de análisis. Estas son aquellas que contienen valores que rompen el orden (código 5: No sabe/No contesta) o que no contienen valor alguno (blanks reales y estructurales). Dado que no es posible modelar con variables que rompen la lógica del comportamiento del fenómeno que se busca entender, que es la satisfacción global, se evaluaron diversas alternativas para el tratamiento de estas celdas. La estrategia utilizada para abordar este problema se exhibe en profundidad en el Apéndice C.2.

Por otro lado, otro cambio realizado antes de plantear el modelo fue la inversión del orden original de las respuestas con el fin de lograr una interpretación más clara de los coeficientes. En consecuencia, tanto la variable de respuesta como los drivers pasan a tener un orden creciente; a cada valor original entre 1 y 4 del feature i se le reemplaza por $feature_{i,creciente} = 5 - feature_i$. De esta forma, la escala queda orientada en sentido creciente: ‘Totalmente satisfecho’ pasa a estar representada por el valor 4, ‘Satisfecho’ por el valor 3, ‘Poco satisfecho’ por el 2 e ‘Insatisfecho’ por el 1. De aquí en adelante, este nuevo orden se mantiene durante todo el desarrollo de la tesis.

Por último, de las 25.117 observaciones de las 13 sucursales seleccionadas, se filtró por el feature `ultima_visita` = menos de 1 semana. Este filtro se hizo con el fin de reducir la posibilidad de que la experiencia de compra del encuestado se vea influenciada por sesgos de memoria [11]. En consecuencia, se modeló con un dataset de 18.739 observaciones.

Una vez consolidada la base de datos para el modelado, se decidió empezar desde el modelo lineal más simple posible, con todos los features desagregados, los controles, género y edad por cuantiles, e intercepto.

$$SAT_i = \alpha + \sum_{k \in \mathcal{K}} \beta_k SP_{ki} + \gamma^\top DEM_i + \varepsilon_i$$

En el modelo:

- i indexa al individuo encuestado.
- SAT_i representa la satisfacción global continua en el intervalo $[1, 4]$ reportada por el individuo i donde 4 es ‘Totalmente satisfecho’ y 1 ‘Insatisfecho’.
- α representa el intercepto.
- $\mathcal{K}$ representa el conjunto de drivers incluidos en el modelo.
- SP_{ki} representa la evaluación continua en el intervalo $[1, 4]$ del driver $k \in \mathcal{K}$ realizada por el individuo i .
- β_k representa la asociación marginal entre el driver k y la satisfacción global, manteniendo constantes el resto de las variables del modelo. Dado que los drivers fueron centrados, este coeficiente se interpreta como el cambio esperado en la satisfacción global ante un aumento de una unidad del driver respecto a su media.
- $DEM = \{\text{edad por cuantiles, género}\}$ representa el conjunto de variables demográficas consideradas.
- DEM_i representa el vector de variables demográficas del individuo i .
- γ representa el vector de coeficientes asociado a las variables demográficas.
- ε_i representa el término de error del modelo.

En términos generales, en el modelo desarrollado, los coeficientes permiten observar qué dimensiones de la experiencia en sucursal están más asociadas con la satisfacción global, manteniendo constantes el resto de los drivers y los controles demográficos. Para que los coeficientes resulten más interpretables, las variables fueron centradas, de modo que el cero ya no representa una respuesta posible de la escala, sino el valor medio de cada feature. Esto es importante para la interpretación, porque los coeficientes siguen midiendo el cambio esperado en la satisfacción global ante un aumento de una unidad en el driver, pero ahora ese cambio se interpreta respecto al promedio de la variable. Este centrado resultó fundamental, dado que permitió, a su vez, asignar valor cero a los blanks estructurales sin tratarlos como una respuesta real. En esos casos, la variable simplemente no aporta un efecto diferencial para esa observación.

Los coeficientes se estimaron mediante mínimos cuadrados ordinarios. Dado que los diagnósticos sobre los residuos mostraron evidencia de heterocedasticidad, la inferencia se

reporta utilizando errores estándar robustos HC3. Esta corrección no modifica los coeficientes estimados, pero sí los errores estándar, los intervalos de confianza y los p-valores asociados. La metodología se encuentra detallada en el Apéndice C.4.

Para complementar la lectura por driver, también se analizó si los efectos se concentran en algunos bloques en particular. Para eso, se construyó una medida descriptiva simple a partir de los coeficientes significativos. Sea $\mathcal{S}$ el conjunto de drivers significativos del modelo

$$\mathcal{S} = \{k : \hat{\beta}_k \text{ es significativo}\}.$$

Para cada bloque b , se calculó el peso absoluto como

$$W_b = \sum_{k \in \mathcal{S} \cap b} |\hat{\beta}_k|.$$

Luego, para expresar ese peso en términos relativos, se calculó

$$P_b = \frac{W_b}{\sum_{b' \in \mathcal{B}} W_{b'}}.$$

3.2. Desbalance en la satisfacción global y modelos ponderados

La distribución de la satisfacción global presenta categorías fuertemente desbalanceadas. La mayor parte de las respuestas se concentra en los niveles altos de satisfacción, mientras que las categorías de menor satisfacción tienen una frecuencia mucho más baja, como se puede observar en la Figura 3.1.




Fig. 3.1: Distribución de la satisfacción global en la muestra de entrenamiento.

Este desbalance constituye un problema para la estimación e interpretación del modelo, dado que un ajuste por mínimos cuadrados ordinarios tiende a estar dominado por las

categorías más frecuentes. En consecuencia, el modelo puede presentar un buen desempeño global, pero explica peor los casos de menor satisfacción, que son, justamente, los de mayor interés desde el punto de vista del análisis.

En consecuencia, se decidió estimar también modelos ponderados. La idea fue corregir parcialmente el peso que tiene cada categoría dentro del ajuste, asignando mayor importancia a las observaciones pertenecientes a categorías menos frecuentes. De esta forma, los casos de menor satisfacción no quedan tan diluidos dentro de una muestra dominada por respuestas positivas. Los pesos y el criterio para asignar se reportan en el Apéndice C.5.

Bajo este criterio de ponderación, se consideraron dos formas de agrupar las categorías de satisfacción global. La primera y más intuitiva fue respetar las categorías originales y usar cuatro pesos distintos para ponderar (WLS 4cat). Sin embargo, como se describió anteriormente, esto representa un problema, dado que se le otorga demasiado peso a una categoría (1-‘Insatisfecho’) que apenas concentra el 0,2 % de las observaciones. El resultado es un modelo altamente inestable, con pocos coeficientes relevantes y desviaciones estándar muy altas para la mayoría de ellos.

En consecuencia, se decidió agrupar las categorías 1-‘Insatisfecho’ y 2-‘Poco satisfecho’ solo para calcular los pesos del modelo. Esto permite reducir la incertidumbre que aparecía al ponderar la categoría 1 por separado, sin eliminar esos casos del análisis. Es importante aclarar que la variable target no se recodifica a una escala de tres valores: la satisfacción global se sigue modelando en su escala original de 1 a 4. Lo que cambia es que las observaciones con satisfacción 1 y 2 reciben el mismo peso, correspondiente al grupo de baja satisfacción. De esta forma, la ponderación queda definida sobre tres grupos ordenados, $1 || 2 < 3 < 4$, mientras que la regresión sigue ajustando la satisfacción global como una variable numérica entre 1 y 4. Los drivers mantienen su escala original entre 1 y 4.

Se obtuvo un modelo más estable (WLS 3cat) y con coeficientes más interpretables (p-valores bajos, intervalos de confianza más pequeños). Esto se ve con más detalle en la tabla del Apéndice C.11.

3.3. Validación cruzada temporal

En una primera lectura, el modelo ponderado resultó más razonable. No obstante, fué pertinente pensar en algún criterio para comparar la robustez entre los tres modelos. El R^2 y el R^2 ajustado son útiles como primera medida de ajuste, pero se calculan sobre la misma muestra utilizada para estimar el modelo. Por lo tanto, no son suficientes para evaluar si el modelo mantiene un comportamiento razonable al tratar de predecir para observaciones no utilizadas durante la estimación.

Asimismo, se incorporó el análisis de qué tan buena es la capacidad predictiva del modelo como indicador de fiabilidad inferencial sobre los coeficientes. Para esto, se decidió utilizar cross-validation (*CV*). Dado que la satisfacción global presenta algunas variaciones entre olas, se decidió tenerlas en cuenta al momento de dividir los datos. Por esta razón, no se utilizó una partición aleatoria, sino un *CV* temporal. Esta decisión va en línea con el trabajo de Roberts et al. [16], cuando los datos tienen estructura temporal, una partición aleatoria puede ofrecer una evaluación demasiado optimista. Por eso, en este caso se respetó el orden de las olas, entrenando con períodos anteriores y validando sobre períodos posteriores.

Los resultados completos se presentan en el Apéndice C.6. En resumen, el modelo inicial sin ponderar presenta los menores errores globales, pero el modelo con tres categorías mejora el R^2 , el Error Absoluto Medio (MAE) y el Error Cuadrático Medio (MSE), ajustados y ponderados por categorías, sin caer en la inestabilidad del modelo ponderado con cuatro categorías. Por esta razón, se tomó el modelo con tres categorías como referencia para la interpretación.

3.4. Reducción de drivers: PCA y feature selection

Una vez seleccionado el modelo ponderado con tres categorías, se evaluó si era posible reducir la cantidad de drivers manteniendo un desempeño similar al del modelo completo. Este último incluye 33 drivers, lo que permite una lectura completa de la experiencia, pero también puede dificultar la inferencia debido a la cantidad de coeficientes a analizar.

Por esta razón, se consideraron dos caminos para reducir la complejidad del modelo. El primero fue utilizar PCA, con el objetivo de resumir los drivers en pocas componentes principales. El segundo fue utilizar un método de feature selection, buscando conservar un subconjunto menor de drivers originales. Ambas estrategias reducen la cantidad de variables, pero no tienen la misma interpretación. En el caso de PCA, los drivers originales dejan de aparecer de forma directa en el modelo y pasan a estar resumidos en componentes. Esto puede ser útil desde el punto de vista estadístico, porque permite trabajar con muy pocas variables, pero dificulta la interpretación de los resultados.

Esto es importante para el objetivo de esta tesis. La idea es poder identificar qué aspectos concretos de la experiencia en sucursal se asocian con la satisfacción global, utilizando la calidad del ajuste como criterio de robustez. Desde el punto de vista interpretativo del negocio, resulta más útil considerar drivers desagregados o agrupados en bloques de forma tal que tengan algún sentido real (ej: precio, surtido, infraestructura, etc), que componentes principales formadas por combinaciones pertenecientes a varios bloques distintos.

No obstante, se decidió explorar el modelado utilizando como variables una cantidad de componentes principales del PCA sobre los datos que explicaran alrededor del 50 % de la varianza. Dado que se modificó el dataset original de 13 sucursales físicas a través de imputaciones y filtros, se decidió realizar un nuevo PCA sobre la muestra. Se utilizaron las tres primeras componentes principales, las cuales concentran el 50,33 % de la varianza explicada.

A partir de estas tres componentes, se estimó el modelo

$$SAT_i = \alpha + \sum_{r=1}^R \delta_r PC_{ri} + \gamma^\top DEM_i + \varepsilon_i$$

donde:

- PC_{ri} representa el valor de la componente principal r para el individuo i .
- R representa la cantidad de componentes principales incluidas en el modelo. En este caso, se utiliza $R = 3$.
- δ_r representa la asociación entre la componente principal r y la satisfacción global, manteniendo constantes el resto de las variables del modelo.

El resto de los términos se interpreta de la misma forma que en el modelo base. Como ya se mencionó, a diferencia de los coeficientes asociados a drivers individuales, los coeficientes δ_r no representan el efecto directo de un driver específico. Cada componente principal es una combinación lineal de varios drivers. Es decir, cada componente se construye mezclando los drivers originales con distintos pesos. Estos pesos se denominan loadings, e indican cuánto participa cada driver en la construcción de cada componente principal.

Como los loadings solo muestran cómo se construye cada componente, pero no cómo se relaciona ese componente con la satisfacción global, se buscó traducir el modelo PCA nuevamente a los bloques de drivers. Para esto, se combinaron los coeficientes estimados de cada componente con los loadings de los drivers que forman parte de cada bloque. De esta forma, se obtiene una aproximación de cuánto aporta cada bloque dentro del modelo estimado con componentes principales. Los detalles de cómo se pensó esta combinación se explican en el Apéndice C.7.1.

Este modelo resulta menos directo para interpretar drivers específicos. Por eso, se lo tomó como una alternativa que permite observar qué dimensiones generales de la experiencia quedan más asociadas con la satisfacción global cuando se reduce la información a pocas componentes, más que como el modelo definitivo de interpretación.

En consecuencia, se consideró una segunda estrategia de reducción de variables. En lugar de reemplazar los drivers por componentes principales, esta estrategia busca seleccionar un subconjunto de drivers originales. De esta forma, se reduce la cantidad de variables del modelo, pero se conserva una interpretación directa de cada coeficiente.

Para realizar esta selección de features, se utilizó SFS (Sequential Feature Selection). Se eligió este método porque, entre las alternativas evaluadas, fue el que presentó los mejores resultados, tomando como criterio principal el menor Error Cuadrático Medio fuera de muestra, calculado con las predicciones out-of-fold de la validación cruzada (MSE OOF). Además, conservaba una cantidad intermedia de drivers; no tan amplia como el modelo completo, pero tampoco tan reducida como para perder información útil sobre la experiencia en sucursal. Se detalla lo mencionado en el Apéndice C.7. Se realizó un grid search sobre el parámetro restrictivo de tolerancia (tol) de SFS, alcanzando una cantidad óptima de coeficientes $K = 20$ bajo la restricción $tol = 0,0001$, con error RMSE OOF $\approx 0,540$ (raíz cuadrada del MSE).

Al comparar el modelo reducido por SFS con el modelo completo de 33 drivers, se observa que la reducción de variables no cambia de forma importante la interpretación general. Esto se resume en la Tabla 3.1.

Tab. 3.1: Comparación entre el modelo ponderado completo y el modelo reducido por SFS.

Criterio	Resultado
Drivers significativos en WLS completo	16
Drivers significativos del WLS completo preservados por SFS	16 de 16
Significativos del top 15 que siguen significativos en SFS	13 de 13
Top 10 por magnitud absoluta en WLS completo preservados por SFS	10 de 10
Top 15 por magnitud absoluta en WLS completo preservados por SFS	14 de 15
Signo del coeficiente preservado en SFS	19 de 20
Correlación de rankings de magnitud entre ambos modelos	0,983

Por las razones anteriormente mencionadas, se tomó el modelo WLS 3cat con selección SFS y $K = 20$ drivers como el principal para la inferencia. Esta elección permite trabajar con un modelo más reducido que el de 33 drivers, pero sin perder la interpretación sustantiva de los coeficientes.

3.4.1. Cómo leer los coeficientes

Dado que los drivers fueron centrados, los coeficientes deben interpretarse como asociaciones entre desviaciones respecto a la media del driver y la satisfacción global. Es decir, un coeficiente positivo indica que una evaluación del driver por encima de su media se asocia con mayor satisfacción global, manteniendo constantes el resto de las variables. A su vez, los blanks estructurales fueron llevados a cero, por lo que no aportan una desviación positiva ni negativa respecto a la media del driver.

3.5. Un modelo de satisfacción como variable ordinal

En el modelo anterior, los drivers fueron tratados como variables numéricas centradas. Esta forma de modelar supone que los cambios entre categorías tienen un efecto relativamente homogéneo sobre la satisfacción. Esta suposición puede resultar problemática, dado que las respuestas provienen de una escala ordinal. Es decir, pasar de una evaluación baja a una evaluación intermedia no necesariamente tiene el mismo efecto que pasar de una evaluación intermedia a una evaluación alta. Por esta razón, se estimó un segundo modelo en el que los drivers dejan de ingresar como una única variable numérica y pasan a representarse mediante variables indicadoras.

En este modelo, se toma la categoría 3-‘Satisfecho’ como referencia. Luego, para cada driver, se distingue entre evaluaciones bajas (1||2) y evaluaciones altas (4). De esta forma, el modelo permite comparar por separado cómo se asocia cada tipo de respuesta con la satisfacción global, sin imponer una única relación lineal para todo el rango de la escala.

En consecuencia, el modelo se define de la siguiente forma

$$SAT_i = \alpha + \sum_{k \in \mathcal{K}} \left(\beta_k^- D_{ki}^{1||2} + \beta_k^+ D_{ki}^4 \right) + \gamma^\top DEM_i + \varepsilon_i$$

donde:

- i indexa al individuo encuestado.
- SAT_i representa la satisfacción global continua en el intervalo $[1, 4]$ reportada por el individuo i donde 4 es ‘Totalmente satisfecho’ y 1 ‘Insatisfecho’.
- α representa el intercepto.
- $\mathcal{K}$ representa el conjunto de drivers incluidos en el modelo.
- Para cada driver k , se toma la categoría 3 como categoría de referencia. Es decir, los coeficientes estimados se interpretan siempre en relación con una evaluación intermedia del driver.

- $D_{ki}^{1||2}$ es una variable indicadora que toma valor 1 si el individuo i evaluó el driver k en las categorías 1 o 2, y toma valor 0 en caso contrario. Esta variable representa una evaluación baja del driver.
- D_{ki}^4 es una variable indicadora que toma valor 1 si el individuo i evaluó el driver k en la categoría 4, y toma valor 0 en caso contrario. Esta variable representa una evaluación alta del driver.
- β_k^- representa la diferencia esperada en la satisfacción global asociada a evaluar el driver k como 1||2, en comparación con evaluarlo como 3, manteniendo constantes el resto de las variables del modelo.
- β_k^+ representa la diferencia esperada en la satisfacción global asociada a evaluar el driver k como 4, en comparación con evaluarlo como 3, manteniendo constantes el resto de las variables del modelo.
- $\mathcal{DEM} = \{\text{edad por cuantiles, género}\}$ representa el conjunto de variables demográficas consideradas.
- DEM_i representa el vector de variables demográficas del individuo i .
- γ representa el vector de coeficientes asociado a las variables demográficas.
- ε_i representa el término de error del modelo.

Se mantuvieron los mismos criterios de imputación y filtro de datos.

En este modelo, cada driver aparece dos veces: por un lado, el coeficiente asociado a una evaluación baja (1||2), y por otro lado, el coeficiente asociado a una evaluación alta (4-‘Totalmente satisfecho’). Dado que el modelo tiene intercepto, se tienen 66 variables dummy. En ambos casos, la comparación se realiza contra la categoría 3-‘Satisfecho’, que funciona como referencia ($\beta_k^{Satisfecho} = 0$, para todo $k \in \mathcal{K}$).

Partiendo de la intuición de que una mejor evaluación de un feature debería asociarse con una mayor satisfacción global y una peor evaluación con una menor satisfacción, primero se observó si los coeficientes estimados poseían el signo esperado respecto a la categoría de referencia. Sin embargo, esta primera lectura solo debe interpretarse como meramente descriptiva, ya que en algunos casos los intervalos de confianza incluyen el cero.

Por esta razón, se adoptó un criterio más restrictivo para identificar los drivers con una relación más estable respecto a la categoría de referencia. Se marcaron aquellos casos en los que el coeficiente asociado a una evaluación alta es positivo, el coeficiente asociado a una evaluación baja es negativo, y ambos intervalos de confianza al 95 % no contienen el cero. En estos casos, el modelo permite afirmar con mayor respaldo que una evaluación alta se asocia positivamente con la satisfacción global, mientras que una evaluación baja se asocia negativamente, siempre con respecto al valor de referencia $\beta_k^{Satisfecho}$.

3.5.1. Medida de loss aversion para la asimetría entre evaluaciones bajas y altas

La idea de loss aversion refiere a una posible asimetría entre pérdidas y ganancias. En el contexto de la satisfacción del cliente, esto implica que una mala evaluación de un driver puede pesar más que una buena evaluación del mismo. Es decir, no se busca solamente

ver si una evaluación baja reduce la satisfacción y una evaluación alta la aumenta, sino comparar si la caída asociada a la evaluación baja es mayor que el aumento asociado a la evaluación alta.

A partir de lo calculado previamente, se añadió una medida de comparación para evaluar que, para un mismo driver, la caída asociada a una evaluación baja es mayor que el aumento asociado a una evaluación alta.

Para cada driver k , se definió la siguiente medida

$$\Delta_k = |\beta_{\text{baja},k}| - \beta_{\text{alta},k}.$$

Dado que, en los casos esperados, $\beta_{\text{baja},k} < 0$ y $\beta_{\text{alta},k} > 0$, esta expresión también puede escribirse como

$$\Delta_k = -\beta_{\text{baja},k} - \beta_{\text{alta},k}.$$

Si $\Delta_k > 0$, la penalización asociada a una evaluación baja es mayor que la recompensa asociada a una evaluación alta. En cambio, si $\Delta_k < 0$, ocurre lo contrario: el efecto positivo tiene mayor magnitud que el negativo. Por lo tanto, esta medida permite resumir de forma simple la comparación entre ambos coeficientes. Sin embargo, este valor debe interpretarse con cuidado. Que Δ_k sea positivo no implica automáticamente que exista evidencia estadística de loss aversion. Para llegar a esa conclusión, también es necesario evaluar si la diferencia entre ambas magnitudes es estadísticamente distinta de cero. Esto es importante porque puede ocurrir que el modelo muestre que una evaluación alta suma y una evaluación baja resta, pero que la diferencia entre ambos efectos no sea lo suficientemente grande como para considerarla significativa.

Para concluir que la asimetría es estadísticamente significativa, hace falta contrastar directamente si Δ_k es distinto de cero; esto se explica con más detalle en el Apéndice C.8.

3.5.2. Chequeo de robustez con SFS

Como criterio de robustez, también se estimó una versión reducida del modelo utilizando SFS. En este caso, la selección se hizo a nivel de driver y no sobre dummies individuales. Es decir, si un driver era seleccionado, entraban al modelo sus dos variables indicadoras: β_k^+ y β_k^- . Esto es importante porque la comparación entre el efecto positivo y el negativo solo tiene sentido si ambos coeficientes están presentes para el mismo driver.

La idea es observar si los drivers con una señal compatible con loss aversion se mantenían luego de reducir la cantidad de variables. Para esto, se realizó un grid search sobre distintos valores del parámetro de tolerancia (tol) del SFS. El criterio fue minimizar el error fuera de muestra. Como resultado, quedaron seleccionados $K = 15$ drivers para $tol = 0,0001$, con un RMSE OOF $\approx 0,528$.

Cabe aclarar que el SFS no selecciona drivers por su nivel de asimetría, sino por su aporte al error cuadrático medio fuera de muestra (MSE OOF) del CV para el modelo considerado. Por lo tanto, un driver puede mostrar una señal clara de loss aversion en el modelo completo, pero no ser seleccionado por SFS si su mejora en términos de error es muy pequeña o negativa.

Por esta razón, el modelo reducido se utiliza como chequeo de robustez, pero la interpretación principal de loss aversion se realiza a partir del modelo completo. Para un análisis más exhaustivo, ver el Apéndice C.8.

5. CONCLUSIONES

La presente tesis desarrolla un marco de análisis para la identificación, cuantificación y evaluación de los determinantes (drivers) de la satisfacción del cliente en una cadena de supermercados, abarcando el período comprendido entre junio de 2021 y marzo de 2026. A lo largo del trabajo, se desarrolló una estrategia de análisis crítica y progresiva, cuyo recorrido está orientado a evaluar distintos aspectos de la problemática.

El punto de partida de esta investigación aborda la fragmentación de la información original, compuesta inicialmente por más de 34.000 encuestas recolectadas bajo cuatro versiones estructurales de cuestionarios. Frente a este escenario, se realizó una unificación de preguntas y variables mediante relaciones de equivalencia y la implementación del algoritmo de Imputación Múltiple mediante Ecuaciones Encadenadas (MICE). Esta técnica permitió tratar consistentemente las respuestas no evaluativas y los datos faltantes, lo que, sumado a la restricción regional de 13 sucursales con cobertura temporal completa y a la aplicación de filtros de control de última visita para reducir el sesgo de memoria, permitió consolidar una base de modelado final de 18.739 observaciones.

Posteriormente, la caracterización y exploración del set de datos puso de manifiesto dos desafíos importantes: por un lado, una distribución marcadamente asimétrica y desbalanceada de la variable de satisfacción global hacia calificaciones sobresalientes; y, por el otro, una alta redundancia distributiva y correlación interna entre los atributos operativos de infraestructura, servicio y calidad, observada también mediante análisis de componentes principales. Este diagnóstico mostró que la estimación directa mediante herramientas estándar de regresión lineal por mínimos cuadrados tradicionales podía generar problemas de interpretación por colinealidad y por el desbalance de la variable target, por lo que fue necesario reconfigurar la estrategia inferencial hacia modelos capaces de contemplar dicha complejidad.

Respondiendo a esta necesidad, la estrategia de modelado avanzó de forma progresiva partiendo de la formulación lineal más sencilla por Mínimos Cuadrados Ordinarios (OLS) para utilizarla como base de contraste. Al evidenciar sus limitaciones, se implementó una transición hacia un esquema de Mínimos Cuadrados Ponderados (WLS) diseñado para compensar el desbalance de la variable target, integrándole en paralelo un algoritmo de Selección Secuencial de Características (SFS). La validez de cada cambio metodológico se puso a prueba empíricamente a través de un esquema de validación cruzada temporal. Estos resultados mostraron que la optimización lineal permitía aislar un núcleo parsimonioso de $K = 20$ variables interpretables sin degradar la capacidad de generalización del modelo.

Uno de los aportes de la tesis fue no suponer que los drivers de satisfacción actúan de forma necesariamente lineal y simétrica. Al permitir una comparación entre evaluaciones bajas y altas de un mismo atributo, se encontró evidencia compatible con loss aversion en algunos drivers. Estos resultados sugieren que, en la muestra analizada, una mala evaluación de ciertos atributos puede penalizar la satisfacción global más de lo que una buena evaluación la aumenta. De todos modos, esta lectura no implica que todos los drivers actúen siempre bajo esta lógica, sino que se identificaron asimetrías relevantes en algunos casos.

Finalmente, la segmentación del modelado por formato de tienda mostró que la sensi-

bilidad del consumidor no parece ser completamente transversal ni homogénea dentro de la cadena.

A modo de conclusión general, esta tesis muestra que un tratamiento cuidadoso de la base y una estrategia de modelado progresiva permiten construir una lectura más rica de la satisfacción del cliente. Los resultados no solo identifican drivers promedio de satisfacción, sino que también muestran posibles asimetrías en algunos atributos y diferencias relevantes según el formato de tienda.

Apéndice A

CONSTRUCCIÓN DE LA BASE UNIFICADA

A.1. Tipos de cuestionario y períodos de aplicación

En esta sección se describe el proceso de fusión de los tipos de encuesta, con el fin de obtener una base de datos unificada. Para ello, primero se presenta cómo se clasificaron las encuestas según el tipo de cuestionario. Esta clasificación no fue definida arbitrariamente, sino a partir de la información proporcionada por la empresa respecto a los cambios que tuvo el formulario a lo largo del tiempo. Es decir, una encuesta pertenece a un tipo u otro según la ola temporal en la que fue realizada, como se presenta en la tabla [A.1](#)

Tab. A.1: Tipos de cuestionario según período de aplicación.

Tipo de cuestionario	Período de aplicación
Tipo 1	junio de 2021 – agosto de 2021
Tipo 2	septiembre de 2021 – abril de 2024
Tipo 3	mayo de 2024 – febrero de 2026
Tipo 4	marzo de 2026 en adelante

Esta distinción es relevante porque cada tipo de cuestionario presenta una estructura propia. Algunas preguntas se mantienen a lo largo del tiempo, otras cambian de ubicación, algunas aparecen solo en ciertos tipos, y, además, dentro de un mismo cuestionario pueden existir distintas rutas de respuesta. Por esta razón, no era posible concatenar directamente los archivos sin realizar antes un proceso de unificación.

La fusión (merge) de los 40 archivos a disposición resultó necesaria para poder realizar un correcto uso de las muestras. Dadas las diferencias entre los tipos de cuestionario e incluso entre cuestionarios dentro de un mismo tipo (cambios entre olas temporales), se evidenció la necesidad de unificarlos.

A continuación, se describe y formaliza este proceso de unificación paso a paso.

A.2. Colapso de preguntas equivalentes

En primer lugar, se describe cómo la existencia de distintas rutas dentro de los cuestionarios afectó la estructura de las variables originales.

Las diferencias entre sucursales, en términos de tamaño y servicios disponibles, explican por qué el cuestionario no tuvo una estructura única para todos los encuestados. En consecuencia, no todos respondieron al mismo conjunto de preguntas dentro de un mismo cuestionario. El recorrido dentro del formulario dependió, en parte, de la sucursal en la que cada encuestado había realizado su última compra. En este contexto, un mismo aspecto evaluado podía aparecer en distintas versiones de una pregunta: estas compartían varias subpreguntas en común, pero diferían en la inclusión o exclusión de ciertos aspectos asociados a servicios disponibles únicamente en algunas sucursales.

Este procedimiento se realizó sobre todas las muestras, independientemente del tipo de cuestionario.

La Figura A.1 resume esquemáticamente este procedimiento. A continuación, se presenta su formalización.



Fig. A.1: Ejemplo de colapso de preguntas equivalentes, ubicadas en distintas rutas del cuestionario, en una única variable canónica.

A.2.1. Formalización

Sea c un tipo de cuestionario, llamamos I_c a la cantidad total de preguntas que lo componen. Por lo tanto, el índice de pregunta i toma valores en $\{1, \dots, I_c\}$.

Dada una pregunta i de c , se define el conjunto

$$\mathcal{P}_{c,i} = \{P_{c,i,j} : j = 1, \dots, J_{c,i}\},$$

donde $P_{c,i,j}$ representa la subpregunta j asociada a la pregunta i del tipo de cuestionario c , y $J_{c,i}$ representa la cantidad total de subpreguntas asociadas a dicha pregunta.

En el caso de preguntas simples, es decir, preguntas que no se subdividen, se toma $J_{c,i} = 1$. Estas preguntas quedan representadas como un único elemento $P_{c,i,1}$.

Se define además una relación de equivalencia $\sim$ entre subpreguntas originales. Se dice que

$$P_{c,i,j} \sim P_{c,\ell,m}$$

si ambas subpreguntas refieren al mismo aspecto evaluado, aún cuando pertenezcan a distintas preguntas o rutas dentro del mismo tipo de cuestionario c .

De esta manera, para cada aspecto evaluado final d que se desea construir en la base unificada, por ejemplo, variedad de alimentos, limpieza de sucursal o calidad de carne, se puede definir un conjunto de subpreguntas equivalentes

$$\mathcal{E}_{c,d} = \{P_{c,i_1,j_1}, P_{c,i_2,j_2}, \dots, P_{c,i_k,j_k}\},$$

tal que todos sus elementos son equivalentes entre sí bajo la relación $\sim$.

Sea $U_{o,c}$ el conjunto de observaciones correspondientes a una ola temporal o , asociada al tipo de cuestionario c . Cada observación $u \in U_{o,c}$ tiene asociada una sucursal s_u , en la cual el encuestado realizó su última compra en la cadena, y sigue una ruta r_{c,s_u} única dentro del tipo de cuestionario c .

Para cada observación $u \in U_{o,c}$, se denota por $Y_{c,i,j}^{(u)}$ la respuesta registrada en la subpregunta $P_{c,i,j}$.

En este contexto, se define r_{c,s_u} como el conjunto de subpreguntas que forman parte de la ruta correspondiente a la observación u . Por lo tanto, una respuesta $Y_{c,i,j}^{(u)}$ solo puede estar definida si $P_{c,i,j} \in r_{c,s_u}$.

Dado un conjunto de observaciones $\mathcal{O}_{c,o,d} \subseteq U_{o,c}$ en la ola o , asociado al aspecto evaluado final d , con

$$\mathcal{O}_{c,o,d} = \{u_{h_1}^{(o)}, u_{h_2}^{(o)}, \dots, u_{h_n}^{(o)}\},$$

se tiene que para todo $u_{h_t}^{(o)} \in \mathcal{O}_{c,o,d}$, existe $P_{c,i_t,j_t} \in \mathcal{E}_{c,d} \cap r_{c,s_{u_{h_t}^{(o)}}}$ tal que $u_{h_t}^{(o)}$ responde a P_{c,i_t,j_t} . Siendo $Y_{c,i_t,j_t}^{(u_{h_t}^{(o)})}$ su correspondiente respuesta.

Al tratarse de observaciones distintas, estas pertenecen a filas distintas dentro del dataset. A su vez, las subpreguntas contenidas en $\mathcal{E}_{c,d}$ corresponden a columnas diferentes. Dado que las rutas dentro de un mismo tipo de cuestionario son excluyentes, para una misma observación $u \in U_{o,c}$ no puede haber más de una subpregunta de $\mathcal{E}_{c,d}$ perteneciente a su ruta r_{c,s_u} . Es decir, si $P_{c,i_a,j_a}, P_{c,i_b,j_b} \in \mathcal{E}_{c,d}$ y además $P_{c,i_a,j_a}, P_{c,i_b,j_b} \in r_{c,s_u}$, entonces necesariamente $a = b$.

Bajo esta condición, para cada observación $u_{h_t}^{(o)} \in \mathcal{O}_{c,o,d}$, se define el valor colapsado como

$$V_{o,d}^{(u_{h_t}^{(o)})} = Y_{c,i_t,j_t}^{(u_{h_t}^{(o)})}.$$

Si para una observación $u \in U_{o,c}$ no existe ninguna respuesta $Y_{c,i,j}^{(u)}$ definida asociada a una subpregunta $P_{c,i,j} \in \mathcal{E}_{c,d}$, entonces el valor correspondiente permanece nulo. Por lo tanto, este procedimiento no modifica ni imputa respuestas, sino que únicamente reorganiza en una misma variable respuestas equivalentes provenientes de distintas rutas.

La columna colapsada asociada al aspecto evaluado d en la ola o queda dada por

$$V_{o,d} = \left(V_{o,d}^{(u)} \right)_{u \in U_{o,c}}.$$

Finalmente, se considera el conjunto de aspectos evaluados finales definidos para la ola temporal o , $\mathcal{D}_o = \{d_1, d_2, \dots, d_{p_o}\}$. Para cada $d_r \in \mathcal{D}_o$, la variable V_{o,d_r} representa la columna del dataset colapsado asociada al aspecto d_r .

$$\mathcal{B}_o^{\text{col}} = [V_{o,d_1} \mid V_{o,d_2} \mid \dots \mid V_{o,d_{p_o}}].$$

De esta forma, $\mathcal{B}_o^{\text{col}}$ representa el dataset colapsado correspondiente a la ola o , construido a partir de la concatenación de todas las columnas $V_{o,d}$ asociadas a los aspectos evaluados finales de dicha ola.

A.3. Construcción de una estructura común entre tipos de cuestionario

Una vez realizado el colapso de preguntas equivalentes dentro de cada ola temporal, el siguiente paso consistió en llevar las variables de los distintos tipos de cuestionario a una

estructura común. Para esta etapa, se decidió utilizar como referencia el tipo 4, por tratarse de la versión más reciente. Esta versión es el resultado de distintas modificaciones que la empresa consideró pertinentes realizar a lo largo del tiempo. En consecuencia, se adoptó como la estructura de referencia más representativa entre los cuatro tipos disponibles en la actualidad.

Se pudo observar que, en términos de complejidad estructural y cantidad de preguntas, los cuestionarios tendieron a simplificarse con el tiempo. En consecuencia, el tipo 4 constituye una versión más reducida de los tipos anteriores, especialmente en comparación con los tipos 1 y 2. El tipo 3 resulta prácticamente idéntico al tipo 4, con la excepción de algunos detalles relacionados con las promociones, lo cual es esperable dado el carácter dinámico de este tipo de contenidos.

Por esta razón, se decidió tomar las preguntas y subpreguntas existentes en el tipo 4 como punto de partida y evaluar su presencia en el resto de los tipos de cuestionario. De este modo, se definió un núcleo final de variables comparables a lo largo del tiempo. Quitando los bloques asociados a Marketing/Publicidad, se identificó un núcleo principal vinculado a la satisfacción general, precio, calidad, variedad, relación precio-calidad, competencia y demografía, que persistió a lo largo del período analizado, aunque con distintos niveles de detalle según el tipo de cuestionario.

Dada la similitud entre los tipos 3 y 4, este proceso resulta más sencillo para ese caso. En cambio, los tipos 1 y 2 requirieron un tratamiento más cuidadoso, dada su mayor extensión y sus diferencias estructurales respecto a los cuestionarios más recientes.

La Figura A.2 resume esquemáticamente este procedimiento. A continuación, se presenta su formalización.




Fig. A.2: Esquema de construcción de una estructura común entre tipos de cuestionario a partir del tipo 4 como referencia.

A.3.1. Formalización

Sea una ola o , y $\mathcal{B}_o^{\text{col}}$ su dataset colapsado.

Se define

$$\mathcal{D}_4 = \{d_1, d_2, \dots, d_q\}$$

el conjunto de aspectos evaluados para el cuestionario tipo 4 y $\mathcal{D}_4^{\text{ref}}$ aquellos aspectos considerados relevantes para el análisis, tal que $\mathcal{D}_4^{\text{ref}} \subseteq \mathcal{D}_4$.

Se considera $\mathcal{D}_c$ para cada tipo de cuestionario $c \neq 4$.

Cada $d \in \mathcal{D}_c$ ya tiene asociado un conjunto $\mathcal{E}_{c,d}$ definido anteriormente y, por lo tanto, puede generar una columna colapsada $V_{o,d}$ en cada ola o para ese tipo.

Sea $c \neq 4$, se define la función de correspondencia

$$\phi_c : \mathcal{D}_4^{\text{ref}} \rightarrow \mathcal{D}_c \cup \{\emptyset\}.$$

Esta función asocia un aspecto $d_a \in \mathcal{D}_4^{\text{ref}}$ a $d_c \in \mathcal{D}_c$ en caso de que exista correspondencia ($\phi_c(d_a) = d_c$) o al vacío en caso de que no ($\phi_c(d_a) = \emptyset$).

Ya en el dataset, si la ola o pertenece al tipo de cuestionario c , entonces para cada aspecto d_a se define una nueva columna estandarizada W_{o,d_a} tal que $W_{o,d_a} = V_{o,d_c}$. Es decir, se toma la columna colapsada que corresponde en esa ola y se lleva a la estructura de referencia.

Si $\phi_c(d_a) = \emptyset$, entonces W_{o,d_a} queda como una columna nula para esa ola.

Finalmente, todas las olas quedan con la misma estructura y los aspectos evaluados d_a pasan a ser features o variables

$$\mathcal{B}_o^{\text{std}} = [W_{o,d_1} \mid W_{o,d_2} \mid \dots \mid W_{o,d_k}]$$

donde

$$\mathcal{D}_4^{\text{ref}} = \{d_1, d_2, \dots, d_k\}$$

con $k \leq q$.

Para luego obtener el dataset final concatenando verticalmente las olas estandarizadas

$$\mathcal{B}^{\text{final}} = \text{concat}(\mathcal{B}_{o_1}^{\text{std}}, \mathcal{B}_{o_2}^{\text{std}}, \dots, \mathcal{B}_{o_T}^{\text{std}}).$$

Apéndice C

DECISIONES METODOLÓGICAS PARA EL MODELADO

C.1. Reorganización de bloques de drivers

En esta sección, se presenta el detalle de la reorganización de bloques realizada antes de la etapa de modelado. Como se mencionó en la sección principal, esta reorganización no modificó los valores de las variables originales, sino la forma en que los drivers fueron agrupados para facilitar la interpretación de los modelos.

En algunos casos, el cambio consistió solamente en renombrar bloques para que fueran más claros. Por ejemplo, el bloque ‘Calidad’ pasó a llamarse ‘Calidad de productos’, y el bloque ‘Infraestructura’ pasó a llamarse ‘Ambiente e infraestructura’. En otros casos, se realizaron cambios de clasificación, porque algunos bloques originales mezclaban variables que podían interpretarse mejor si se separaban en dimensiones distintas.

El cambio más importante fue la separación del bloque original ‘Atención / servicio’. Este bloque reunía variables vinculadas al trato del personal y variables asociadas a tiempos de espera. Para mejorar la interpretación, se separó en dos dimensiones: ‘Personal y atención’ y ‘Esperas y conveniencia operativa’. Esto puede tener sentido si se piensa que la amabilidad o disponibilidad del personal no mide necesariamente lo mismo que la espera en caja, carnicería o fiambrería.

También se definió el bloque ‘Ofertas y promociones’, que agrupa variables relacionadas con la disponibilidad y el atractivo de las ofertas. Estas variables estaban originalmente repartidas entre bloques como ‘Surtido / disponibilidad’ y ‘Precios’, pero para el modelado resultó más claro tratarlas como una dimensión propia.

Tab. C.1: Comparación entre bloques originales y bloques finales.

Bloque original	Bloque final	Tipo de cambio
Surtido / disponibilidad	Surtido y disponibilidad	Renombre
Calidad	Calidad de productos	Renombre
Precios	Precio	Renombre
Relación calidad-precio	Valor percibido / relación calidad-precio	Renombre conceptual
Infraestructura	Ambiente e infraestructura	Renombre
Atención / servicio	Personal y atención	Reasignación real
Atención / servicio	Esperas y conveniencia operativa	Reasignación real
Surtido / disponibilidad	Ofertas y promociones	Reasignación real
Precios	Ofertas y promociones	Reasignación real

La mayoría de los cambios consistieron en renombres realizados para que los bloques fueran más claros. Sin embargo, también hubo algunos cambios de clasificación. Estos casos corresponden a variables que, para la etapa de modelado, resultaba más razonable ubicarlas en otro bloque porque el nuevo agrupamiento representa mejor lo que esas variables están midiendo.

En particular, el cambio de ‘Infraestructura’ a ‘Ambiente e infraestructura’ buscó que

el nombre del bloque fuera más representativo de las variables que contiene. Algunas variables, como carritos y canastos o baños, se refieren claramente a elementos físicos de la tienda, pero también forman parte de la experiencia general del cliente en sucursal. Por eso, el nombre ‘Ambiente e infraestructura’ permite capturar mejor esa doble dimensión: por un lado, los aspectos materiales del espacio y, por otro, cómo esos elementos afectan la comodidad de la experiencia de compra.

Tab. C.2: Variables reasignadas entre bloques.

Variable	Feature	Bloque original	Bloque final
var_05	Disponibilidad productos en oferta	Surtido / disponibilidad	Ofertas y promociones
precio_07	Atractivo de las ofertas	Precios	Ofertas y promociones
atencion_01	Disponibilidad del personal	Atención / servicio	Personal y atención
atencion_06	Amabilidad del personal	Atención / servicio	Personal y atención
atencion_02	Espera en carnicería	Atención / servicio	Esperas y conveniencia operativa
atencion_03	Espera en fiambrería	Atención / servicio	Esperas y conveniencia operativa
atencion_04	Espera en rotisería	Atención / servicio	Esperas y conveniencia operativa
atencion_05	Espera en caja	Atención / servicio	Esperas y conveniencia operativa

La separación más relevante fue la del bloque ‘Atención / servicio’. En la clasificación original, este bloque combinaba variables asociadas al trato del personal con variables asociadas a tiempos de espera. En la clasificación final, estas dimensiones quedaron separadas en ‘Personal y atención’ y ‘Esperas y conveniencia operativa’. Esto puede tener sentido si se piensa que la amabilidad o disponibilidad del personal no necesariamente mide lo mismo que la espera en caja, carnicería o fiambrería.

Además, se creó el bloque ‘Ofertas y promociones’, que reúne variables asociadas específicamente a la disponibilidad y al atractivo de las ofertas. Esto permite distinguirlas del surtido general y del nivel de precios, que representan dimensiones relacionadas, pero no idénticas.

C.2. Tratamiento de valores faltantes y código 5

Una vez obtenido el dataset unificado, seleccionados los features que serán utilizados como variables explicativas y definida la satisfacción global como variable de respuesta, surgió un problema importante para el modelado. En algunos casos, el encuestado respondió ‘No sabe/No contesta’ o ‘No corresponde’, mientras que en otros la celda aparece directamente vacía. Por lo tanto, antes de pasar a la etapa de modelado, fue necesario distinguir estas situaciones y definir cómo tratarlas.

Cada uno de estos casos representa un problema distinto y requiere un análisis particular para decidir cómo tratarlo.

Es importante aclarar que, para el tipo de modelo utilizado, los drivers se utilizan como variables continuas. En consecuencia, los valores imputados con MICE no se redondearon.

Se los mantuvo dentro del rango válido de la escala, pero como valores continuos. Redondearlos podría hacer perder parte de la información generada por MICE y forzar valores enteros de manera innecesaria.

C.2.1. Caracterización de celdas problemáticas

En primer lugar, se tuvo que resolver un problema asociado a la pérdida de información importante durante el merge. Los blanks o espacios vacíos se categorizaron en dos tipos: blanks reales y blanks estructurales. Los primeros corresponden a casos en los que el encuestado no respondió, a pesar de que le correspondía por ruta dentro del cuestionario. Y los segundos, a casos donde el encuestado no debió responder por pertenecer la subpregunta a una ruta que no le corresponde.

Durante el merge, esta distinción se pierde durante la etapa de colapso interno en la ola. Si un encuestado no respondió cuando justo no le correspondía (ej: la sucursal a la que fue no tiene baño), cuando se haga el colapso, la variable final quedará en blank.

Lo mismo ocurrirá si el encuestado no responde cuando sí le correspondía; se colapsa y la celda queda en blank.

Esto representa un problema, dado que, una vez hecho el colapso, no hay forma de distinguir un espacio vacío relevante, es decir, real, de uno no correspondido por pertenecer a una ruta distinta. Para resolver este problema, se recurrió a un diccionario, sabiendo que la ruta dentro de cada tipo de cuestionario esta obligada a tomar cada sucursal. De esta forma, podemos distinguir las celdas vacías problemáticas de las irrelevantes. Vale la pena aclarar que con irrelevantes se hace referencia al nulo aporte que hacen a la caracterización de la observación. Aún teniendo en cuenta lo anterior, también requieren un trato especial, dado que forman parte del dataset.

En el caso del código 5, este se presentó como un problema de distinta naturaleza: rompe la escala ordinal, pues no es comparable en términos de orden con ninguna otra respuesta válida.

En la Tabla [C.1](#), se muestra cuántas celdas en blanco, estructurales y de código 5 existen en el dataset final.

Distribución de respuestas según tipo de completitud

Total de registros: 828.861




Fig. C.1: Porcentaje de celdas problemáticas.

Dado este contexto, se procedió a hacer un análisis más profundo de los casos de interés; código 5 y blanks reales. Se muestra con más detalle cuántas celdas conflictivas hay por tipo de encuesta y para cada observación, en las Figuras C.2 y C.3.




Fig. C.2: Cantidad de blanks por tipo de encuesta y muestras.




Fig. C.3: Cantidad de código 5 por tipo de encuesta y muestras.

Al observar estos gráficos, se pudo apreciar que un porcentaje muy grande de las observaciones tiene celdas conflictivas. En consecuencia, se hizo razonable la idea de adoptar algún tipo de estrategia de imputación. Dado que las observaciones con este tipo de celdas no pueden ser utilizadas directamente en el modelo, excluirlas de la muestra de entrenamiento implicaría una reducción significativa del tamaño muestral. Además de potencialmente sesgar la muestra, pues podría existir alguna relación entre el resto de las variables de la observación o variables fuera de nuestro alcance que estén condicionando la presencia de este tipo de celdas.

Se procedió a observar si estas celdas presentaban un patrón aleatorio entre las variables.

Se observó una distribución desigual tanto para los blanks reales como para el código 5. La presencia de estas celdas en las observaciones no parece ser completamente azarosa. Por lo tanto, estos patrones no son compatibles con un mecanismo MCAR (Missing Completely At Random).

Las variables asociadas a los tiempos de espera están sobre-representadas en blanks reales. En cambio, para el código 5 se observa una sobrerrepresentación en variables más específicas, es decir, variables que no son universales entre sucursales o que dependen del uso de determinadas secciones. Esto sugiere que ambos tipos de celdas problemáticas no necesariamente responden al mismo mecanismo.

Lo mismo se observó al analizar la distribución por sucursal.

Este análisis fue importante porque muestra que las celdas problemáticas no aparecen distribuidas de forma completamente aleatoria. Sin embargo, a partir de los datos observados, no es posible afirmar de forma concluyente si el mecanismo es MAR (Missing At Random) o MNAR. En este caso, el supuesto MAR debe interpretarse como una hipótesis de trabajo necesaria para aplicar métodos de imputación, no como una propiedad que

pueda verificarse directamente en los datos.

Esta distinción es relevante porque los códigos 5 y los blanks reales parecen responder a lógicas distintas. Los códigos 5 se concentran más en variables asociadas a secciones específicas u opcionales de la tienda, lo que puede estar vinculado al uso efectivo de esas secciones por parte del encuestado. Los blanks reales, en cambio, presentan un patrón más heterogéneo que podría combinar omisión, no uso, fatiga de respuesta, evasión o errores de registro. Por esta razón, la imputación no se tomó como una única solución definitiva, sino como una decisión metodológica que podría ser contrastada a futuro con estrategias alternativas.

C.3. Estrategia de imputación de celdas problemáticas

En esta sección, se presentan formalmente los métodos y criterios utilizados para imputar las celdas problemáticas. Además, se detalla el criterio empleado para decidir qué estrategia de imputación resulta más adecuada.

A partir del análisis anterior, se utilizó MICE como una estrategia de imputación bajo una hipótesis operativa MAR. La idea es que, al menos en parte, los valores problemáticos de una observación pueden estar relacionados con el resto de los features disponibles. MICE permite aprovechar esa información al imputar cada variable condicionando en las demás variables observadas. Este procedimiento se explica en detalle en la sección C.3.1.

Sin embargo, dado que los patrones observados no permiten garantizar que el supuesto MAR se cumpla completamente, también se compararon estrategias alternativas más simples, como imputar por mediana o por media, ya sea del bloque o de la variable. Además, se compararon estas estrategias contra la matriz de correlación pairwise y contra el caso complete-case. De esta forma, la estrategia final de imputación se interpreta como resultado de un análisis de sensibilidad, y no como una afirmación fuerte sobre el verdadero mecanismo de generación de los faltantes.

El criterio utilizado para elegir la estrategia de imputación se basó en comparar las matrices de correlación. Se tomó como referencia la matriz de correlación de Spearman pairwise, R_S^P , y se comparó con la matriz de correlación de Spearman obtenida luego de aplicar cada estrategia de imputación E , R_S^E .

Se decidió utilizar Spearman en lugar de Pearson porque la mayoría de los features provienen de escalas categóricas ordinales. Es decir, si bien las respuestas se representan numéricamente, lo más importante es el orden entre las categorías y no necesariamente la distancia exacta entre ellas. Por esta razón, Spearman resulta más adecuado, ya que calcula la asociación a partir de los rangos de las variables.

C.3.1. MICE (Imputación Múltiple mediante Ecuaciones Encadenadas)

Para imputar los valores faltantes se utilizó MICE, siguiendo la lógica general de imputación múltiple mediante una secuencia de modelos de regresión propuesta por Raghu-nathan et al. (2001) [17].

Sea

$$\mathcal{D}_4^{\text{ref}} = \{d_1, d_2, \dots, d_k\}$$

el conjunto de features.

Sea una muestra $u \in \mathcal{B}^{final}$, y X_{u,d_j} el valor asociado al feature d_j que se desea imputar de u .

Si

$$d_{-j} = \{d_1, \dots, d_{j-1}, d_{j+1}, \dots, d_k\} = \mathcal{D}_4^{\text{ref}} \setminus \{d_j\},$$

entonces d_{-j} representa el conjunto de todos los features menos d_j . Se define

$$X_{u,d_{-j}} = \{X_{u,d_h} : d_h \in d_{-j}, X_{u,d_h} \sim F_{d_h}\}$$

como el conjunto de features de u con valores factibles. Es decir, $X_{u,d_h} \sim F_{d_h}$, con F_{d_h} la distribución asociada al feature d_h .

La idea de MICE es estimar, para cada feature con valores a imputar, una distribución condicional del tipo

$$\widehat{\mathbb{P}}(X_{u,d_j} \mid X_{u,d_{-j}}).$$

Esta distribución aproxima los valores que podría tomar X_{u,d_j} , dado el resto de los valores factibles disponibles para esa observación.

El procedimiento se aplica de forma secuencial. Es decir, se imputa un feature utilizando el resto de los features disponibles, luego se actualizan esos valores imputados y se continúa con otro feature. Este proceso se repite de manera iterativa, formando una cadena de ecuaciones condicionales.

En la imputación múltiple, este procedimiento se repite para $\ell = 1, \dots, m$. En cada repetición se obtiene una base imputada distinta. Por lo tanto, para un valor a imputar X_{u,d_j} , no se obtiene un único valor final, sino una realización posible en cada base imputada:

$$\widehat{X}_{u,d_j}^{(\ell)} \sim \widehat{\mathbb{P}}(X_{u,d_j} \mid X_{u,d_{-j}}), \quad \ell = 1, \dots, m.$$

El parámetro m representa la cantidad de bases imputadas generadas. Por lo tanto, el procedimiento no produce una única versión completada del dataset, sino un conjunto de m bases imputadas,

$$\mathcal{B}^{(1)}, \mathcal{B}^{(2)}, \dots, \mathcal{B}^{(m)}.$$

Cada una de estas bases contiene una versión posible de los valores faltantes. De esta forma, la imputación múltiple permite incorporar parte de la incertidumbre asociada a los valores que no fueron observados.

Luego, el modelo se estima por separado en cada una de las bases imputadas. Si $\widehat{\theta}^{(\ell)}$ representa el estimador obtenido en la base imputada ℓ , la estimación puntual combinada puede escribirse como

$$\bar{\theta} = \frac{1}{m} \sum_{\ell=1}^m \widehat{\theta}^{(\ell)}.$$

Sin embargo, la inferencia final no se basa únicamente en este promedio. También se considera la variabilidad dentro de cada imputación y la variabilidad entre imputaciones, siguiendo la lógica de las reglas de Rubin. Es decir, la imputación múltiple no solo promedia resultados, sino que también incorpora la incertidumbre generada por la completación de valores no observados.

En este trabajo, la estrategia seleccionada se aplicó en dos etapas. Primero, se imputaron los blanks reales aplicables mediante MICE con $m_{\text{blanks}} = 2$. Luego, se imputaron los códigos 5/99 mediante MICE con $m_5 = 2$. Por lo tanto, la cantidad total de bases imputadas utilizadas para combinar los resultados fue

$$m_{\text{total}} = m_{\text{blanks}} \times m_5 = 2 \times 2 = 4.$$

En consecuencia, a diferencia de una imputación única, este procedimiento no depende de una sola reconstrucción posible del dataset, sino que considera distintas versiones factibles de los valores faltantes.

C.3.2. Criterio de selección entre estrategias de imputación

Se decidió utilizar la matriz de correlación pairwise como referencia, dado que esta preserva con un mayor grado de exactitud la correlación entre las variables crudas. Para la misma, los blanks y los 5 se transforman en NaN.

Sea

$$\mathcal{S} = \{(d_j, d_k) : d_j, d_k \in \mathcal{D}_4^{\text{ref}}, 1 \leq j < k \leq K\}.$$

el conjunto de features finales.

Dadas dos matrices de correlación, R^P la matriz de correlación pairwise de una muestra $\mathcal{M}$, y R^E la matriz de correlación imputada con la estrategia E de la misma muestra.

Para un par de variables $(d_j, d_k) \in \mathcal{S}$, se considera la diferencia absoluta entre sus correlaciones en ambas matrices $\text{Corr}_{R^P}^{(d_j, d_k)}$ y $\text{Corr}_{R^E}^{(d_j, d_k)}$ como

$$\Delta_{jk}^{P,E} = |R_{jk}^P - R_{jk}^E|.$$

Se considera a $\Delta_{jk}^{P,E}$ para el par de matrices R^P y R^E como la distancia entre las variables (d_j, d_k) .

En consecuencia, la distancia media entre las variables $\forall (d_j, d_k) \in \mathcal{S}$ se define como

$$\bar{\Delta}^{P,E} = \frac{1}{|\mathcal{S}|} \sum_{(j,k) \in \mathcal{S}} \Delta_{jk}^{P,E}.$$

Es decir, el promedio de la suma de todas las $\Delta_{jk}^{P,E}$ posibles.

Además, si

$$\Delta^{P,E} = \{\Delta_{ih}^{P,E} : (d_i, d_h) \in \mathcal{S}\}$$

$p90(\Delta^{P,E})$ es el conjunto de pares $(d_i, d_h) \in \mathcal{S}$ tales que $\Delta_{ih}^{P,E}$ se encuentra en el percentil 90 del conjunto.

Luego, se define la distancia total entre las matrices de correlaciones P y E , con N_E el tamaño de la muestra para la estrategia de imputación E como

$$C^{P,E} = \frac{\lambda \overline{\Delta}^{P,E} + (1 - \lambda) p_{90}(\Delta^{P,E})}{N_E}, \quad 0 \leq \lambda \leq 1. \quad (\text{score})$$

El parámetro λ determina el peso asignado a la diferencia absoluta media, mientras que $1 - \lambda$ determina el peso asignado al percentil 90.

De esta forma, el criterio no depende solamente del cambio promedio entre correlaciones, sino que también penaliza estrategias que generan diferencias grandes en una proporción relevante de pares de variables. Además, se tiene en cuenta el tamaño de la muestra, priorizando estrategias que conservan una mayor cantidad de observaciones.

En consecuencia, una estrategia de imputación E se considera más cercana a la matriz pairwise que una estrategia E' si

$$C^{P,E} < C^{P,E'}.$$

En este caso, se tomó $\lambda = 0,5$, asignando el mismo peso a la diferencia promedio y al percentil 90 de las diferencias absolutas.

C.3.3. Búsqueda de hiperparámetros óptimos

En MICE, existe la posibilidad de seleccionar cuántas muestras tomar de la función de distribución generada, para luego promediarlas y obtener una estimación más robusta del valor faltante.

Resulta razonable pensar, entonces, en una búsqueda sobre distintas estrategias posibles de tratamiento de celdas problemáticas. Para esto, se definió un conjunto de estrategias candidatas $\mathcal{T}$, que incluye alternativas como imputación mediante MICE, imputación por mediana, imputación por media y combinaciones distintas para blanks reales y códigos 5.

Dado que no todas las estrategias dependen de los mismos parámetros, no se definió un único espacio de hiperparámetros común. En cambio, a cada estrategia $T \in \mathcal{T}$ se le asoció su propio espacio de configuraciones $\mathcal{H}_T$. Un elemento $h \in \mathcal{H}_T$ representa una configuración concreta de esa estrategia. Esta configuración puede incluir una o más decisiones, como la cantidad de imputaciones MICE para blanks reales, la cantidad de imputaciones MICE para códigos 5, o algún criterio de tolerancia sobre la cantidad de celdas problemáticas permitidas por observación.

En este sentido, h no debe interpretarse necesariamente como una tupla de dimensión fija. Su forma depende de la estrategia considerada. Por ejemplo, una estrategia basada solo en mediana puede no requerir parámetros adicionales, mientras que una estrategia combinada puede incluir varias decisiones, como imputar blanks reales con MICE, imputar códigos 5 con MICE y filtrar observaciones con más de cierta cantidad de celdas problemáticas.

De esta forma, el conjunto total de alternativas evaluadas puede escribirse como

$$\mathcal{A} = \bigcup_{T \in \mathcal{T}} (\{T\} \times \mathcal{H}_T).$$

Cada elemento $a = (T, h) \in \mathcal{A}$ representa una alternativa concreta de tratamiento de los datos. Para cada alternativa a , se construyó una matriz de correlaciones de Spearman R^a y se comparó con la matriz de correlaciones por pares R^P , tomada como referencia. Esta última se utilizó porque calcula cada correlación usando las observaciones disponibles para ese par de variables, sin imponer una imputación previa sobre toda la matriz.

Por razones de complejidad computacional, la búsqueda se realizó sobre un conjunto finito de configuraciones. En el caso de los parámetros asociados a MICE, se consideraron valores en $\{2, 5, 10, 15\}$. Para las estrategias que dependían de criterios de filtrado o de tolerancia de celdas problemáticas, se evaluaron los valores correspondientes definidos para cada caso.

El criterio general consistió en elegir la alternativa que minimizara la distancia a la matriz de correlaciones pairwise, según el criterio definido en la ecuación (score). En términos generales, la selección puede expresarse como

$$a^* = \arg \min_{a \in \mathcal{A}} C^{P,a}.$$

Es decir, se eligió la estrategia y configuración que produjo la matriz de correlaciones más cercana a la matriz pairwise, teniendo en cuenta también el tamaño muestral resultante bajo esa alternativa.

La Tabla C.3 muestra la distancia entre la matriz de correlación pairwise y algunos de los métodos de imputación probados.

Tab. C.3: Ranking de estrategias de imputación según distancia a la matriz de correlación Spearman pairwise.

Rank	Estrategia	m_{blanks}	m_5	i	N_E	media	p90	score
1	MICE blanks reales + MICE 5	2	2	–	18.977	0,0214	0,0440	$1,74 \times 10^{-6}$
2	MICE 5 + mediana blanks reales $< i$	–	10	1	14.665	0,0171	0,0395	$1,93 \times 10^{-6}$
3	(MICE 5 + mediana blanks reales) $< i$	–	1	6	12.358	0,0145	0,0349	$2,00 \times 10^{-6}$
4	MICE 5 + mediana blanks reales $< i$	–	1	6	15.831	0,0208	0,0436	$2,03 \times 10^{-6}$
5	Complete-case	–	–	–	4.697	0,0478	0,0739	$1,30 \times 10^{-5}$

Como se observa en la tabla, la mejor alternativa evaluada resultó ser MICE blanks reales + MICE 5. Denotemos esta estrategia como $T_{\text{Blanks},5}^{\text{MICE}}$, donde Blanks representa los blanks reales y 5 los códigos 5. Para esta estrategia particular, el espacio de configuraciones evaluado fue

$$\mathcal{H}_{T_{\text{Blanks},5}^{\text{MICE}}} = \{(m_{\text{Blanks}}, m_5) : m_{\text{Blanks}}, m_5 \in \{2, 5, 10, 15\}\}.$$

Cada configuración $h \in \mathcal{H}_{T_{\text{Blanks},5}^{\text{MICE}}}$ define una alternativa concreta $a = (T_{\text{Blanks},5}^{\text{MICE}}, h)$. A continuación, se muestra la comparación de las alternativas evaluadas para la estrategia “imputar con MICE los códigos 5 y los blanks reales”. Esto se muestra en la Tabla C.4.

Tab. C.4: Resultados de la búsqueda en grilla para MICE blanks reales $\rightarrow$ MICE 5.

m_{blanks}	m_5	Score Spearman ($\times 10^{-6}$)
5	10	1,66
15	10	1,66
10	10	1,66
10	15	1,66
5	15	1,66
15	15	1,67
15	5	1,67
10	2	1,67
10	5	1,68
15	2	1,68
5	5	1,69
5	2	1,69
2	15	1,70
2	10	1,71
2	2	1,74
2	5	1,76

Si bien el mínimo numérico del grid search no corresponde exactamente a la combinación $(m_{\text{Blanks}}, m_5) = (2, 2)$, se decidió adoptar esta estrategia por un criterio metodológico conservador. La diferencia en distancia respecto de la mejor combinación observada es pequeña en términos absolutos (aproximadamente 5 %), mientras que el costo computacional aumenta rápidamente al considerar valores mayores de m_{Blanks} o m_5 .

En particular, la combinación $(2, 2)$ requiere generar una cantidad mucho menor de bases imputadas que alternativas como $(5, 10)$, $(10, 10)$ o $(15, 15)$. Dado que las diferencias en la matriz de correlaciones son pequeñas y las conclusiones inferenciales no cambian sustancialmente, no parece justificarse utilizar una estrategia mucho más costosa solo para obtener una mejora marginal en el score $C^{P,a}$.

Además, al tratarse de un procedimiento estocástico, pequeñas diferencias en el ranking pueden depender de las semillas utilizadas. Por lo tanto, cuando el grid search muestra valores muy cercanos entre sí, no resulta conveniente ser estricto en la elección del mínimo por sobre encima de las demás opciones.

En el caso de los blanks estructurales, el tratamiento fue distinto al de los blanks reales. Estos valores no corresponden a una no respuesta del encuestado, sino a preguntas que no aplicaban por el diseño del cuestionario, por la ruta seguida o por las características de la sucursal. Por lo tanto, no resulta adecuado imputarlos como si fueran respuestas observadas. Es por esto que su valor asignado fue cero. Lo que requirió centrar todas las variables.

De esta forma, el modelo no interpreta la no aplicabilidad como una evaluación positiva, negativa o intermedia del feature. Simplemente, esa variable no interviene en la explicación de la satisfacción global para esa observación.

C.3.4. Blanks estructurales y centrado de variables

Para el modelo simple de satisfacción, tanto pooled como dividido por formato, un caso distinto al de los valores faltantes reales corresponde a los blanks estructurales. Estos

no representan una ausencia de respuesta por parte del encuestado, sino situaciones en las que el feature no aplicaba para la observación, dado que la pregunta no formaba parte de la ruta correspondiente dentro del cuestionario.

Por lo tanto, no resulta adecuado imputar una posible respuesta para estos casos. No obstante, para poder incluir el feature dentro de la matriz de modelado, se decidió asignarles un valor 0 luego de centrar la variable.

Sea S_{u,d_j} un indicador asociado a la observación u y al feature d_j . Se define $S_{u,d_j} = 1$ si el feature d_j corresponde a un blank estructural para la observación u , y $S_{u,d_j} = 0$ si dicho feature formaba parte de la ruta correspondiente.

Para calcular el centro de la variable, se consideran únicamente las observaciones para las cuales el feature era aplicable y tenía un valor definido. Sea

$$\mathcal{A}_j = \{u \in \mathcal{B}^{\text{final}} : S_{u,d_j} = 0, X_{u,d_j} \neq \text{NA}\}.$$

Luego, se define la media del feature d_j como

$$\mu_j = \frac{1}{|\mathcal{A}_j|} \sum_{u \in \mathcal{A}_j} X_{u,d_j}.$$

A partir de esta media, se construye la variable centrada $\tilde{X}_{u,d_j}$ de la siguiente forma:

$$\tilde{X}_{u,d_j} = \begin{cases} X_{u,d_j} - \mu_j, & S_{u,d_j} = 0, \\ 0, & S_{u,d_j} = 1. \end{cases}$$

De esta manera, cuando el feature era aplicable, se utilizaba su valor centrado respecto a la media. En cambio, cuando el feature no aplicaba por tratarse de un blank estructural, se asigna el valor 0.

El centrado es importante porque permite que el 0 no sea interpretado como una categoría de respuesta, sino como ausencia de desviación respecto al valor medio del feature. Por lo tanto, asignar 0 a un blank estructural no equivale a imputar una respuesta, sino a indicar que esa variable no aporta un efecto diferencial para esa observación.

En efecto, si el feature d_j entra al modelo mediante el término

$$\beta_j \tilde{X}_{u,d_j},$$

entonces, para una observación con blank estructural en d_j , se tiene que

$$S_{u,d_j} = 1 \quad \Rightarrow \quad \tilde{X}_{u,d_j} = 0 \quad \Rightarrow \quad \beta_j \tilde{X}_{u,d_j} = 0.$$

Por lo tanto, la observación permanece dentro del modelo, pero sin que se le asigne una respuesta artificial en una pregunta que no le correspondía responder.

C.4. Diagnóstico de heterocedasticidad y errores estándar robustos HC3

Para justificar el uso de errores estándar robustos, se analizó si el supuesto de homocedasticidad era razonable. Este punto es importante porque, si la varianza de los errores no es constante, los errores estándar clásicos pueden dar una medida incorrecta de la incertidumbre de los coeficientes. En ese caso, los coeficientes estimados no cambian, pero sí cambia la forma en que se calcula su incertidumbre. Por eso, ante evidencia de heterocedasticidad, resulta más adecuado reportar errores estándar robustos, siguiendo la idea propuesta por White [18] y las correcciones posteriores de MacKinnon y White [19]. Como el modelo fue estimado sobre distintas bases imputadas, se reporta el mayor p-valor observado entre las imputaciones. Es decir, se toma el caso menos favorable para rechazar la homocedasticidad. Los resultados se muestran en la Tabla C.5.

Tab. C.5: Tests de heterocedasticidad sobre residuos OLS.

Test	p-valor máximo entre imputaciones
Breusch-Pagan / Koenker	$1,18 \times 10^{-45}$
Breusch-Pagan clásico	$2,23 \times 10^{-55}$
White	$1,06 \times 10^{-152}$

Como complemento visual, también se construyó un gráfico de scale-location para el Modelo 1 estimado sobre la primera base imputada. Este gráfico C.4 relaciona los valores ajustados por el modelo con la raíz cuadrada del valor absoluto de los residuos estandarizados. Es decir, en el eje horizontal se ubica el valor predicho por el modelo, mientras que en el eje vertical se representa $\sqrt{|r_i^*|}$, donde r_i^* corresponde al residuo estandarizado de la observación i .




Fig. C.4: Gráfico scale-location para el Modelo 1 sobre la primera base imputada.

Este diagnóstico permite observar si la dispersión de los residuos se mantiene aproximadamente constante a lo largo de los valores ajustados. Bajo homocedasticidad, la línea suavizada debería ser relativamente horizontal, y las medianas por intervalo no deberían mostrar cambios fuertes. En cambio, en la figura se observa que la dispersión no es completamente estable a lo largo del rango de valores predichos. Esto resulta consistente con los tests formales reportados en la Tabla C.5.

A partir de estos resultados, el supuesto de homocedasticidad no parece adecuado para este modelo. Por un lado, los tres tests formales rechazan la hipótesis nula con p-valores extremadamente bajos. Por otro lado, el gráfico scale-location muestra que la dispersión de los residuos no se mantiene completamente estable a lo largo de los valores predichos.

Esto no implica cambiar los coeficientes estimados por OLS, sino la forma en que se calcula la incertidumbre asociada a esos coeficientes. Por esta razón, se decidió reportar errores estándar robustos HC3. Estos errores estándar permiten hacer inferencia sin depender tanto del supuesto de varianza constante del término de error.

La elección de HC3 responde a que es una corrección más conservadora que otras variantes robustas, como HC1 o HC2. En particular, HC3 tiene en cuenta con mayor intensidad la posible presencia de observaciones con alto leverage, es decir, observaciones con combinaciones de valores de las variables explicativas más alejadas del patrón general de la muestra. Esto puede tener sentido en este caso, dado que la muestra es grande, pero también presenta desbalance y evidencia clara de heterocedasticidad.

C.5. Desbalance de la variable de respuesta y modelos ponderados

Cuando la variable de respuesta está muy desbalanceada, el ajuste por mínimos cuadrados ordinarios puede quedar muy condicionado por las categorías más frecuentes. La razón es que OLS pondera igual a cada observación, no a cada categoría. Por lo tanto, una categoría con muchas observaciones tiene mayor peso agregado dentro de la suma de errores que el modelo busca minimizar

$$\min_{\beta} \sum_{i=1}^N (y_i - \hat{y}_i)^2.$$

Para corregir parcialmente este problema, se estimaron modelos ponderados. En este caso, cada observación recibe un peso w_i , de forma que el error de las categorías menos frecuentes tenga mayor incidencia en el ajuste

$$\min_{\beta} \sum_{i=1}^N w_i (y_i - \hat{y}_i)^2.$$

Sea $g(i)$ la categoría a la que pertenece la observación i , y sea $n_{g(i)}$ la cantidad de observaciones en la categoría de la observación i . Los pesos se definieron como

$$w_i = \frac{N}{G \cdot n_{g(i)}},$$

donde N representa el tamaño total de la muestra y G la cantidad de categorías consideradas. De esta forma, las categorías con menor frecuencia reciben un peso individual mayor, mientras que las categorías más frecuentes reciben un peso individual menor.

A continuación en las tablas C.6 y C.7, se muestran los pesos calculados para las dos formas de ponderación consideradas. La primera utiliza las cuatro categorías originales de satisfacción global, mientras que la segunda agrupa algunas categorías para reducir el desbalance extremo de la variable de respuesta.

Tab. C.6: Pesos utilizados para la ponderación con cuatro categorías de satisfacción global.

Q5	Etiqueta	N	w_i
4	Muy satisfecho	7.703	0,608
3	Satisfecho	10.210	0,459
2	Poco satisfecho	784	5,98
1	Insatisfecho	42	112

Tab. C.7: Pesos utilizados para la ponderación con categorías agregadas de satisfacción global.

Q5	Etiqueta	N	w_i
4	Muy satisfecho	7.703	0,811
3	Satisfecho	10.210	0,612
1 2	Baja satisfacción	826	7,56

La comparación entre ambas tablas muestra una diferencia importante. Cuando se ponderan las cuatro categorías por separado, la categoría menos frecuente recibe un peso de 112. En cambio, al agrupar las categorías de menor satisfacción, el peso del grupo bajo se reduce a 7,56.

Por esta razón, la versión agregada resulta más estable. Mantiene dentro del análisis los casos de menor satisfacción, pero evita que una categoría con muy pocas observaciones tenga un peso excesivamente alto en la estimación.

C.6. Evaluación de robustez temporal entre modelos

Para evaluar los modelos fuera de muestra, se utilizó cross-validation (CV) temporal. La idea fue respetar el orden de las olas, de forma que el modelo se entrene con información pasada y se evalúe sobre observaciones posteriores.

Se utilizó una estructura de ventana expansiva. Es decir, en cada fold el conjunto de entrenamiento incorpora todas las olas disponibles hasta cierto momento, y la validación se realiza sobre un bloque temporal posterior. De esta forma, cada observación validada es predicha por un modelo que no la utilizó durante la estimación.

Esto permite obtener predicciones fuera de muestra, también llamadas OOF (out-of-fold). A partir de estas predicciones se calcularon las métricas fuera de muestra utilizadas para comparar el desempeño de los modelos: MAE, RMSE y R^2 OOF.

Para calcular el RMSE OOF, primero se concatenaron las predicciones obtenidas en los bloques de validación de los cuatro folds. Si V_f representa el conjunto de observaciones validadas en el fold f , el conjunto OOF puede escribirse como

$$V_{\text{OOF}} = \bigcup_{f=1}^F V_f,$$

donde $F = 4$ y cada observación pertenece al bloque de validación de un único fold. De esta forma, todas las predicciones incluidas en el cálculo fueron generadas por modelos que no utilizaron esas observaciones durante la estimación.

A partir de las predicciones concatenadas, el RMSE OOF ponderado se calculó como

$$\text{RMSE}_{\text{OOF}} = \sqrt{\frac{\sum_{f=1}^F \sum_{i \in V_f} w_i \left(y_i - \hat{y}_i^{(-f)} \right)^2}{\sum_{f=1}^F \sum_{i \in V_f} w_i}},$$

donde y_i es el valor observado, $\hat{y}_i^{(-f)}$ es la predicción para la observación i obtenida con el modelo entrenado sin utilizar el bloque de validación V_f , y w_i es el peso asignado a esa observación.

Para los modelos WLS, el RMSE OOF se calculó utilizando los pesos w_i . En el caso del modelo OLS, la métrica se calculó sin ponderación, lo que equivale a tomar $w_i = 1$ para todas las observaciones. Por lo tanto, la diferencia entre ambos casos se encuentra únicamente en la incorporación de los pesos dentro de las sumas.

Es importante aclarar que este cálculo no consiste en promediar los RMSE obtenidos en cada fold. Como los bloques de validación tienen distinto tamaño y pueden tener distinta suma de pesos, un promedio simple otorgaría la misma importancia a todos los folds. En cambio, al concatenar las predicciones OOF y calcular una única métrica, cada observación participa de acuerdo con su peso en el conjunto completo de validación.

El R^2 OOF se calculó siguiendo la misma lógica. Primero se concatenaron las predicciones de los bloques de validación y luego se comparó el error del modelo con la variabilidad total de la variable objetivo dentro del conjunto OOF. Para los modelos ponderados, la expresión utilizada fue

$$R_{\text{OOF}}^2 = 1 - \frac{\sum_{f=1}^F \sum_{i \in V_f} w_i \left(y_i - \hat{y}_i^{(-f)} \right)^2}{\sum_{f=1}^F \sum_{i \in V_f} w_i \left(y_i - \bar{y}_{w, \text{OOF}} \right)^2},$$

donde

$$\bar{y}_{w, \text{OOF}} = \frac{\sum_{f=1}^F \sum_{i \in V_f} w_i y_i}{\sum_{f=1}^F \sum_{i \in V_f} w_i}$$

es la media ponderada de la variable objetivo en el conjunto OOF.

Para los modelos WLS, el R^2 OOF se calculó utilizando los pesos w_i y la media ponderada $\bar{y}_{w,\text{OOF}}$. En el caso del modelo OLS, se tomó $w_i = 1$ para todas las observaciones, por lo que la media ponderada se reemplaza por la media aritmética de la variable objetivo en el conjunto OOF.

Al igual que con el RMSE, se calculó un único R^2 después de concatenar todas las predicciones OOF y no un promedio de los valores obtenidos en cada fold.

Además de estas métricas, se reportan dos medidas asociadas al ajuste del modelo completo: el R^2 ajustado del modelo y el R^2 ajustado general. Estas medidas no son OOF ni corresponden al test final, sino que se incluyen como información adicional para comparar los modelos.

En cada fold, la imputación MICE se realizó después de separar entrenamiento y validación, es decir, usando solamente las observaciones del conjunto de entrenamiento. Luego, esos criterios se aplicaron tanto al entrenamiento como al bloque de validación.

De esta forma, la validación no se usó para aprender las relaciones necesarias para imputar. Esto evita que información del bloque evaluado entre en el proceso de entrenamiento. En esta etapa, además, se utilizó una versión promediada de las imputaciones dentro de cada fold. Es decir, para el CV se trabajó con una única base imputada por fold. Por lo tanto, no se estimaron cuatro modelos separados para luego combinarlos mediante reglas de Rubin, como sí se hace en el ajuste final.

El centrado de las variables siguió la misma lógica. Las medias utilizadas para centrar los features se calcularon solamente con el conjunto de entrenamiento de cada fold, y luego se aplicaron también al conjunto de validación. Así, el bloque validado no interviene ni en la imputación ni en el cálculo de los centros usados para transformar las variables.

Además de los folds del CV temporal, se reservó un test final con observaciones posteriores. Este test se utilizó como chequeo adicional fuera de muestra. Para esta evaluación final, el modelo se entrenó con las olas disponibles hasta julio de 2025 y se evaluó sobre las olas posteriores, desde septiembre de 2025 hasta marzo de 2026.

La imputación y el centrado siguieron la misma lógica que en los folds anteriores: se estimaron únicamente con el entrenamiento final y luego se aplicaron al conjunto de test final.

Las métricas del test final se calcularon de la misma manera, pero utilizando únicamente las observaciones reservadas para ese conjunto.

Tab. C.8: Estructura del CV temporal y test final.

Fold / conjunto	Entrenamiento	Validación / test	N evaluación
Fold 1	jun. 2021 – dic. 2023	ene. 2024 – may. 2024	1.974
Fold 2	jun. 2021 – may. 2024	jul. 2024 – nov. 2024	1.495
Fold 3	jun. 2021 – nov. 2024	ene. 2025 – mar. 2025	568
Fold 4	jun. 2021 – mar. 2025	may. 2025 – jul. 2025	1.198
Test final	jun. 2021 – jul. 2025	sep. 2025 – mar. 2026	1.770

La Tabla C.9 muestra las métricas fuera de muestra para los tres modelos considerados. Se reportan las métricas OOF del CV temporal y las métricas del test final. Es importante remarcar que todas las métricas están ponderadas, a excepción de OLS 33 drivers.

Tab. C.9: Métricas de desempeño fuera de muestra y test final.

Modelo	MAE OOF	RMSE OOF	R^2 OOF	MAE test	RMSE test	R^2 test
OLS 33 drivers	0,337	0,433	0,448	0,326	0,420	0,467
WLS 3cat 33 drivers	0,413	0,540	0,602	0,400	0,525	0,619
WLS 4cat 33 drivers	0,538	0,708	0,599	0,439	0,558	0,751

La Tabla C.10 muestra métricas del modelo completo. Estas métricas no son OOF ni corresponden al test final; sin embargo, se reportan para complementar la comparación entre modelos.

Tab. C.10: Métricas de ajuste del modelo completo.

Modelo	R^2 adj. modelo	R^2 adj. general
OLS 33 drivers	0,436	0,436
WLS 3cat 33 drivers	0,605	0,314
WLS 4cat 33 drivers	0,727	0,0683

Como se observa en la Tabla C.9, el modelo OLS presenta los menores errores globales fuera de muestra. Sin embargo, entre los modelos ponderados, el modelo WLS 3cat presenta menores errores que el WLS 4cat, tanto en las métricas OOF como en el test final.

Además, como se observa en la Tabla C.10, el modelo WLS 4cat alcanza el mayor R^2 ajustado del modelo, pero presenta errores fuera de muestra mayores que el WLS 3cat. En cambio, el modelo WLS 3cat permite corregir parte del desbalance sin aumentar tanto los errores de predicción. Esta diferencia también se observa en la Tabla C.11, al comparar la cantidad de drivers significativos, los SE y los intervalos de confianza de cada modelo.

Tab. C.11: Precisión de los coeficientes estimados por modelo.

Modelo	Drivers $p < 0,05$	SE med.	SE media	IC95 % med.	IC95 % media	IC95 % máx.
OLS 33 drivers	22	0,00890	0,00880	0,0347	0,0345	0,0449
WLS 3cat 33 drivers	16	0,0211	0,0214	0,0825	0,0837	0,108
WLS 4cat 33 drivers	4	0,0781	0,0790	0,306	0,310	0,535

C.7. Comparación de criterios de Feature selection y ajuste de SFS

C.7.1. Cálculo del aporte aproximado por bloque en el modelo PCA

Como complemento, se calculó un aporte aproximado por bloque para el modelo estimado con las primeras tres componentes principales. Este cálculo se utilizó para interpretar cómo se distribuía el peso del modelo PCA entre los bloques conceptuales de drivers.

El modelo estimado puede escribirse como

$$Q5_i = \alpha + \beta_1 PC1_i + \beta_2 PC2_i + \beta_3 PC3_i + \text{controles}_i + \varepsilon_i.$$

A su vez, cada componente principal es una combinación lineal de los drivers originales. Si x_{ij} representa el valor del driver j para la observación i , y l_{jk} representa el loading del driver j en la componente k , entonces

$$PCk_i = \sum_{j=1}^K l_{jk} x_{ij}.$$

Por lo tanto, el aporte aproximado del driver j a través de la componente k se calculó como

$$\text{aporte}_{j,k} = \beta_k l_{jk}.$$

Luego, para pasar de drivers a bloques, se sumaron los aportes de todos los drivers pertenecientes a cada bloque. Si B_b representa el conjunto de drivers del bloque b , el aporte del bloque b a través de la componente k se definió como

$$A_{b,k} = \sum_{j \in B_b} \beta_k l_{jk}.$$

Finalmente, el aporte neto del bloque se obtuvo sumando los aportes de las tres componentes consideradas:

$$A_b^{\text{neto}} = A_{b,1} + A_{b,2} + A_{b,3}.$$

Esta cuenta debe interpretarse como una aproximación. El modelo PCA no estima un coeficiente directo para cada driver, sino para componentes que combinan varios drivers al mismo tiempo. Por eso, lo que se hace es repartir el coeficiente de cada componente entre los drivers usando sus loadings, y luego sumar esos aportes dentro de cada bloque.

C.7.2. Comparación de criterios de selección de features

Luego de analizar el modelo basado en componentes principales, se compararon distintos criterios de selección de features para el modelo WLS 3cat. La idea fue evaluar si era posible reducir la cantidad de drivers sin perder desempeño fuera de muestra y, al mismo tiempo, lograr una buena interpretación del modelo.

Esta comparación es importante porque no todos los métodos abordan el problema de la misma forma. El modelo con PCA resume la información en componentes, pero sus coeficientes no corresponden directamente a drivers del cuestionario. En cambio, los métodos de selección directa conservan las variables originales. Esto permite interpretar el modelo en términos de drivers concretos de la experiencia en sucursal.

Todos los criterios fueron comparados sobre la misma estrategia de imputación, centrado y ponderación WLS 3cat. De esta forma, las diferencias observadas no se deben a cambios en la construcción de la matriz de modelado, sino al criterio utilizado para seleccionar features.

En el caso de SFS, la selección se realizó de forma secuencial utilizando como criterio interno la minimización del error cuadrático medio. Es decir, en cada paso se incorporó el driver que producía la mayor mejora bajo ese criterio. Luego, para comparar SFS con el resto de los métodos, se evaluaron los modelos resultantes con las mismas métricas fuera de muestra: MAE, RMSE y R^2 OOF ponderados.

Por lo tanto, la Tabla C.12 no compara necesariamente el criterio interno utilizado por cada método, sino el desempeño final de los modelos obtenidos bajo cada estrategia de selección. Esto permite evaluar si la reducción de drivers mejora o mantiene el desempeño respecto al modelo completo.

Tab. C.12: Comparación de criterios de selección de features para el modelo WLS 3cat.

Método / especificación	k drivers	MAE OOF	RMSE OOF	R^2 OOF
WLS ponderado 3cat	33	0,413	0,540	0,602
SFS ponderado 3cat	20	0,412	0,538	0,605
Permutation ponderado 3cat	28	0,413	0,539	0,604
ElasticNetCV ponderado 3cat	27	0,413	0,539	0,603
RFE ponderado 3cat	17	0,412	0,539	0,603
Bootstrap robustos WLS 3cat	8	0,414	0,542	0,599

Como se observa, el modelo SFS ponderado 3cat presenta el mejor desempeño en RMSE y R^2 OOF. Además, queda prácticamente empatado en MAE con RFE. Si bien RFE obtiene un MAE apenas menor, la diferencia es mínima, mientras que SFS presenta menor RMSE y mayor R^2 fuera de muestra. Por esta razón, se decidió priorizar SFS como criterio principal de selección.

También se observa que los métodos Permutation y ElasticNetCV seleccionan una cantidad elevada de drivers, cercana al modelo completo de 33 variables, pero sin mejorar el desempeño fuera de muestra. En este sentido, no parecen aportar una reducción suficiente de la complejidad del modelo. El criterio bootstrap robusto, en cambio, selecciona un modelo mucho más pequeño, con 8 drivers, pero con una pérdida mayor en las métricas de evaluación.

Por lo tanto, SFS ofrece un punto intermedio razonable. Reduce la cantidad de drivers, mantiene una lectura directa de las variables seleccionadas y no genera una pérdida de desempeño fuera de muestra significativa en comparación con el modelo completo. Por esta razón, se lo utilizó como criterio principal para definir el modelo reducido.

C.7.3. Ajuste del criterio SFS auto-k

Una vez elegido SFS como criterio principal de selección, quedaba definir cuántos drivers incluir en el modelo reducido. En lugar de fijar manualmente un valor de k , se utilizó una versión auto-k. La idea fue evaluar distintos valores de tolerancia y dejar que el procedimiento seleccionara la cantidad de drivers a partir de la mejora marginal observada.

En este trabajo, esta mejora se tomó como la reducción del MSE ponderado con la métrica weighted 3cat en validación temporal al agregar un driver más al modelo. Es decir, si MSE_k representa el error del modelo con k drivers, la mejora de pasar de $k - 1$ a k drivers puede escribirse como

$$\Delta MSE_k = MSE_{k-1} - MSE_k.$$

A partir de esto, el procedimiento sigue incorporando drivers mientras la reducción del error sea mayor que la tolerancia definida

$$MSE_{k-1} - MSE_k > \text{tol.}$$

Cuando esa mejora deja de superar la tolerancia, el procedimiento se detiene. Esto puede tener sentido si se piensa que, al principio, agregar drivers suele reducir bastante el MSE, pero después llega un punto en que cada driver adicional aporta cada vez menos. En ese caso, seguir agregando variables aumenta la complejidad del modelo sin mejorar de forma relevante el desempeño fuera de muestra.

Para cada valor de tolerancia en

$$tol = \{1 \times 10^{-5}, 5 \times 10^{-5}, 1 \times 10^{-4}, 5 \times 10^{-4}, 1 \times 10^{-3}, 5 \times 10^{-3}, 1 \times 10^{-2}\}$$

se obtuvo un conjunto de drivers seleccionado por SFS, y luego se evaluó el desempeño fuera de muestra del modelo resultante.

Tab. C.13: Grid search del criterio SFS auto-k para el modelo WLS 3cat.

tol	k	consenso	MAE	MSE	RMSE	R ²
5×10^{-5}	20		0,410	0,290	0,538	0,601
1×10^{-5}	20		0,410	0,290	0,538	0,601
1×10^{-4}	20		0,410	0,290	0,538	0,601
1×10^{-3}	12		0,413	0,293	0,541	0,597
5×10^{-4}	15		0,413	0,293	0,541	0,597
5×10^{-3}	7		0,416	0,296	0,544	0,592
1×10^{-2}	5		0,423	0,308	0,555	0,575

Como se observa en la Tabla C.13, los valores de tolerancia 5×10^{-5} , 1×10^{-5} y 1×10^{-4} producen el mismo resultado: seleccionan 20 drivers y obtienen las mismas métricas fuera de muestra. En consecuencia, el óptimo del grid search quedó asociado a un modelo con $k = 20$ drivers y $tol = 10^{-4}$.

A medida que la tolerancia aumenta, el procedimiento se vuelve más restrictivo y selecciona menos drivers. Esto reduce la complejidad del modelo, pero también empeora las métricas fuera de muestra. Por ejemplo, con $tol = 0,001$ el modelo queda con 12 drivers y el MSE aumenta a 0,293, mientras que con $tol = 0,01$ el modelo queda con solo 5 drivers y el MSE aumenta a 0,308.

Por esta razón, se decidió modelar con SFS auto-k $k = 20$. Esta alternativa mantiene el mejor desempeño observado en el criterio de selección y, al mismo tiempo, reduce la cantidad de drivers respecto del modelo completo de 33 variables.

C.8. Robustez del modelo de loss aversion

En esta sección, se presentan resultados adicionales del modelo de loss aversion. El objetivo es complementar la lectura de la sección principal.

Como ya se mencionó anteriormente, para cada driver se calculó la medida de asimetría

$$\Delta_k = |\beta_k^-| - \beta_k^+.$$

Esta medida compara la magnitud del efecto asociado a una evaluación baja con el efecto asociado a una evaluación alta. Cuando $\Delta_k > 0$, la evaluación baja tiene mayor peso, en valor absoluto, que la evaluación alta.

En el caso esperado, donde $\beta_k^- < 0$ y $\beta_k^+ > 0$, la medida anterior puede escribirse como

$$\Delta_k = -\beta_k^- - \beta_k^+.$$

Entonces, el contraste de simetría puede plantearse mediante la siguiente hipótesis nula

$$H_0 : \beta_k^- + \beta_k^+ = 0,$$

$$H_1 : \beta_k^- + \beta_k^+ \neq 0.$$

En el caso esperado, este contraste es equivalente a evaluar

$$H_0 : \Delta_k = 0.$$

A partir de los coeficientes estimados, la medida de asimetría se calcula como

$$\hat{\Delta}_k = -\hat{\beta}_k^- - \hat{\beta}_k^+.$$

Como ambos coeficientes se estiman dentro del mismo modelo, el error estándar de $\hat{\Delta}_k$ debe considerar no solo la varianza de cada estimador, sino también la covarianza entre ellos. Por lo tanto,

$$SE(\hat{\Delta}_k) = \sqrt{\text{Var}(\hat{\beta}_k^-) + \text{Var}(\hat{\beta}_k^+) + 2 \text{Cov}(\hat{\beta}_k^-, \hat{\beta}_k^+)}.$$

Las varianzas y la covarianza se obtienen a partir de la matriz de varianzas y covarianzas del modelo. De esta forma, se tiene en cuenta que los dos coeficientes no fueron estimados de manera independiente.

El estadístico utilizado para realizar el contraste es

$$z_k = \frac{\hat{\Delta}_k}{SE(\hat{\Delta}_k)}.$$

Para un nivel de significancia del 5 %, se rechaza H_0 cuando

$$|z_k| > 1,96.$$

De manera equivalente, también se puede construir el intervalo de confianza

$$IC_{95\%}(\Delta_k) = \hat{\Delta}_k \pm 1,96 SE(\hat{\Delta}_k).$$

Si este intervalo no contiene al cero, la diferencia entre ambas magnitudes se considera estadísticamente significativa.

Si la hipótesis nula se rechaza, hay evidencia de que ambos efectos no son simétricos para ese driver. Sin embargo, el sentido de la asimetría depende del signo de $\hat{\Delta}_k$. Cuando $\hat{\Delta}_k > 0$, la asimetría va en el sentido esperado por una lógica de loss aversion, ya que la penalización asociada a una evaluación baja es mayor que la recompensa asociada a una evaluación alta. En cambio, cuando $\hat{\Delta}_k < 0$, ocurre lo contrario: el efecto positivo tiene mayor magnitud que el negativo, lo que puede interpretarse como reward dominance.

Es importante aclarar que este test no es lo mismo que observar si cada coeficiente es significativo por separado. En el modelo principal se evalúa si el coeficiente asociado a una evaluación baja es distinto de cero y si el coeficiente asociado a una evaluación alta también es distinto de cero, ambos respecto de la categoría de referencia. En cambio, el contraste de asimetría evalúa si la diferencia entre ambas magnitudes es estadísticamente distinta de cero.

Esto puede tener sentido si se piensa que el modelo podría mostrar que una evaluación baja resta y que una evaluación alta suma, pero que la diferencia entre ambos efectos no sea suficientemente grande como para afirmar que la penalización es mayor que la

recompensa. Por eso, para hablar de loss aversion en términos estadísticos, no alcanza con que $\hat{\Delta}_k > 0$: también es necesario que esa diferencia sea significativa.

Como chequeo adicional, se comparó el modelo completo de 33 drivers con una versión reducida obtenida mediante SFS auto-k aplicado al modelo de loss aversion. La idea fue verificar si la reducción de variables modificaba de forma importante los coeficientes positivos, negativos y las medidas de asimetría.

Para esta comparación, el SFS auto-k se aplicó a nivel de driver y no sobre dummies individuales. Es decir, cada driver ingresaba o salía del modelo con sus dos indicadores: evaluación baja (1||2) y evaluación alta (4). Esto permite conservar la comparación entre ambos efectos.

Tab. C.14: Comparación entre modelo completo y modelo reducido por SFS auto-k en el modelo de loss aversion.

Métrica	Valor
R^2 ajustado modelo completo 33 drivers	0,622
R^2 ajustado modelo SFS auto-k loss aversion	0,609
Correlación coeficientes positivos	0,985
Correlación coeficientes negativos	0,978
Correlación medidas de asimetría	0,950

Las correlaciones de la Tabla C.14 se calcularon sobre los $K = 15$ drivers seleccionados por el procedimiento SFS auto-k. Es decir, se compararon los coeficientes estimados para esos mismos drivers en el modelo completo de 33 drivers y en el modelo reducido.

Como se observa, el modelo reducido presenta un R^2 ajustado algo menor que el modelo completo, pero mantiene correlaciones altas en los coeficientes positivos, negativos y en las medidas de asimetría. Esto sugiere que la reducción de variables no modifica de forma importante la lectura general del modelo de loss aversion.

Apéndice E

LIBRERÍAS UTILIZADAS EN LA IMPLEMENTACIÓN COMPUTACIONAL

En este apéndice, se presentan las principales librerías utilizadas en la implementación. La idea no es describir en detalle cómo funciona cada una, sino dejar documentadas las herramientas que se usaron durante el procesamiento de los datos, la construcción de variables, la imputación, la estimación de modelos y la generación de resultados.

Tab. E.1: Principales librerías utilizadas en el análisis.

Librería	Uso principal
pandas	Lectura, limpieza, transformación y unión de bases; armado de tablas y exportación de resultados.
numpy	Cálculo numérico, operaciones con arreglos, máscaras, medias, errores y trabajo matricial.
matplotlib	Generación de gráficos principales, como gráficos de barras, heatmaps, coeficientes, curvas y diagnósticos.
openpyxl	Escritura y formato de archivos Excel, incluyendo hojas, estilos, colores, tablas e inserción de imágenes.
statsmodels	Estimación de modelos estadísticos y econométricos, como OLS y WLS, modelos con fórmulas, diagnósticos, tests e inferencia.
scipy	Tests estadísticos, correlaciones, clustering jerárquico, distancias y funciones de distribución.
scikit-learn	Imputación MICE, PCA, estandarización, validación cruzada, selección de variables y métricas predictivas.
Pillow / PIL	Edición puntual de imágenes y figuras, como agregar leyendas o referencias visuales.
geopandas	Elaboración de mapas y visualizaciones geográficas de sucursales.

Como se observa, las librerías cumplen funciones distintas dentro del trabajo. Algunas fueron utilizadas principalmente para preparar la base de datos, otras para estimar modelos y realizar contrastes estadísticos, y otras para generar gráficos o salidas auxiliares.

Bibliografía

- [1] W. Bruce Traill. The rapid rise of supermarkets? nature, causes, and impacts. *Development Policy Review*, 24(2):163–174, 2006.
- [2] Nic S. Terblanche. Revisiting the supermarket in-store shopping experience. *Journal of Retailing and Consumer Services*, 40:48–59, 2018.
- [3] Óscar González-Benito. Spatial and structural analysis of retail competition. *International Journal of Retail & Distribution Management*, 33(3):218–233, 2005.
- [4] Dhruv Grewal and Michael Levy. Retailing research: Past, present and future. *Journal of Retailing*, 83(4):447–452, 2007.
- [5] Omid Kamran-Disfani, Murali K. Mantrala, Alicia Izquierdo-Yusta, and María Pilar Martínez-Ruiz. The competitive impacts of a new store format: A structural analysis. *Journal of Retailing*, 93(4):453–469, 2017.
- [6] Katri Koistinen and Raija Järvinen. Consumer grocery shopping profiles: Connections between shopping behavior and store format choice. *International Journal of Retail & Distribution Management*, 37(1):54–77, 2009.
- [7] Michael Levy, Barton A. Weitz, and Dhruv Grewal. *Retailing Management*. McGraw-Hill/Irwin, Boston, 8th edition, 2010.
- [8] Thomas Reutterer and Christoph Teller. Store format choice and shopping trip types. *Journal of Business Research*, 62(12):1199–1210, 2009.
- [9] Patrick Van Kenhove, Walter Van Waterschoot, and Kristof De Wulf. Impact of task definition on store-attribute saliences and store choice. *Journal of Retailing*, 75(1):125–137, 1999.
- [10] Pratibha A. Dabholkar, Dayle I. Thorpe, and Joseph O. Rentz. A measure of service quality for retail stores: Scale development and validation. *Journal of the Academy of Marketing Science*, 24(1):3–16, 1996.
- [11] Marcel Goić, Camilo Levenier, and Ricardo Montoya. Drivers of customer satisfaction in the grocery retail industry: A longitudinal analysis across store formats. *Journal of Retailing and Consumer Services*, 60:102505, 2021.
- [12] Eugene W. Anderson and Vikas Mittal. Strengthening the satisfaction-profit chain: The asymmetric effects of negative and positive performance. *Journal of Marketing Research*, 37(4):421–434, 2000.
- [13] Daniel Kahneman and Amos Tversky. Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2):263–291, 1979.
- [14] Shin'ya Suzuki, Reginald B. Mitchell, and Rajshekhar G. Javalgi. Asymmetric effects of service quality on customer satisfaction in international services. *Journal of Services Marketing*, 15(7):542–558, 2001.

- [15] Amos Tversky and Daniel Kahneman. Loss aversion in riskless choice: A reference-dependent model. *The Quarterly Journal of Economics*, 106(4):1039–1061, 1991.
- [16] David R. Roberts, Volker Bahn, Simone Ciuti, Mark S. Boyce, Jane Elith, Gurutzeta Guillera-Arroita, Severin Hauenstein, José J. Lahoz-Monfort, Boris Schröder, Wilfried Thuiller, David I. Warton, Brendan A. Wintle, Florian Hartig, and Carsten F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929, 2017.
- [17] Trivellore E. Raghunathan, James M. Lepkowski, John Van Hoewyk, and Peter Solenberger. A multivariate technique for multiply imputing missing values using a sequence of regression models. *Survey Methodology*, 27(1):85–95, 2001. Catalogue No. 12-001.
- [18] Halbert White. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4):817–838, 1980.
- [19] James G. MacKinnon and Halbert White. Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3):305–325, 1985.